# Analítica de Datos

## Clase 3 - Data Cleaning e Intro a Machine Learning

## ¿Qué vieron con Pablo?

El martes pasado y antes
del finde largo...

# Agenda

- Data Cleaning
- Intro Machine Learning
- Regresión Lineal
- Notebooks
- Kahoot

# Data Prepping / Cleaning

*¿Qué es el data cleaning/prepping?*

# Data Prepping / Cleaning

*¿Qué es el data cleaning/prepping?*

El proceso de preparar y limpiar los datos antes de analizarlos

# Data Prepping / Cleaning

*¿Qué es el data cleaning/prepping?*

El proceso de preparar y limpiar los datos antes de analizarlos

*¿Por qué hacemos data prepping?*

# Data Prepping / Cleaning

*¿Qué es el data cleaning/prepping?*

El proceso de preparar y limpiar los datos antes de analizarlos

*¿Por qué hacemos data prepping?*

Preparamos los datos para que sean correctos, consistentes y útiles, así podemos confiar en lo que analizamos o modelamos.

# Data Prepping / Cleaning

*¿Qué es el data cleaning/prepping?*

El proceso de preparar y limpiar los datos antes de analizarlos

*¿Por qué hacemos data prepping?*

Preparamos los datos para que sean correctos, consistentes y útiles, así podemos confiar en lo que analizamos o modelamos.

*¿Por qué hacemos data prepping?*

# Data Prepping / Cleaning

*¿Qué es el data cleaning/prepping?*

El proceso de preparar y limpiar los datos antes de analizarlos

*¿Por qué hacemos data prepping?*

Preparamos los datos para que sean correctos, consistentes y útiles, así podemos confiar en lo que analizamos o modelamos.

*¿Qué pasa si no lo hacemos?*

Sin data prepping, es muy probable que obtengas malos modelos y decisiones poco confiables

# Data Prepping / Cleaning

*¿Qué es el data cleaning/prepping?*

El proceso de preparar y limpiar los datos antes de analizarlos

*¿Por qué hacemos data prepping?*

Preparamos los datos para que sean correctos, consistentes y útiles, así podemos confiar en lo que analizamos o modelamos.

*¿Qué pasa si no lo hacemos?*

Sin data prepping, es muy probable que obtengas malos modelos y decisiones poco confiables

**Un ejemplo...???**

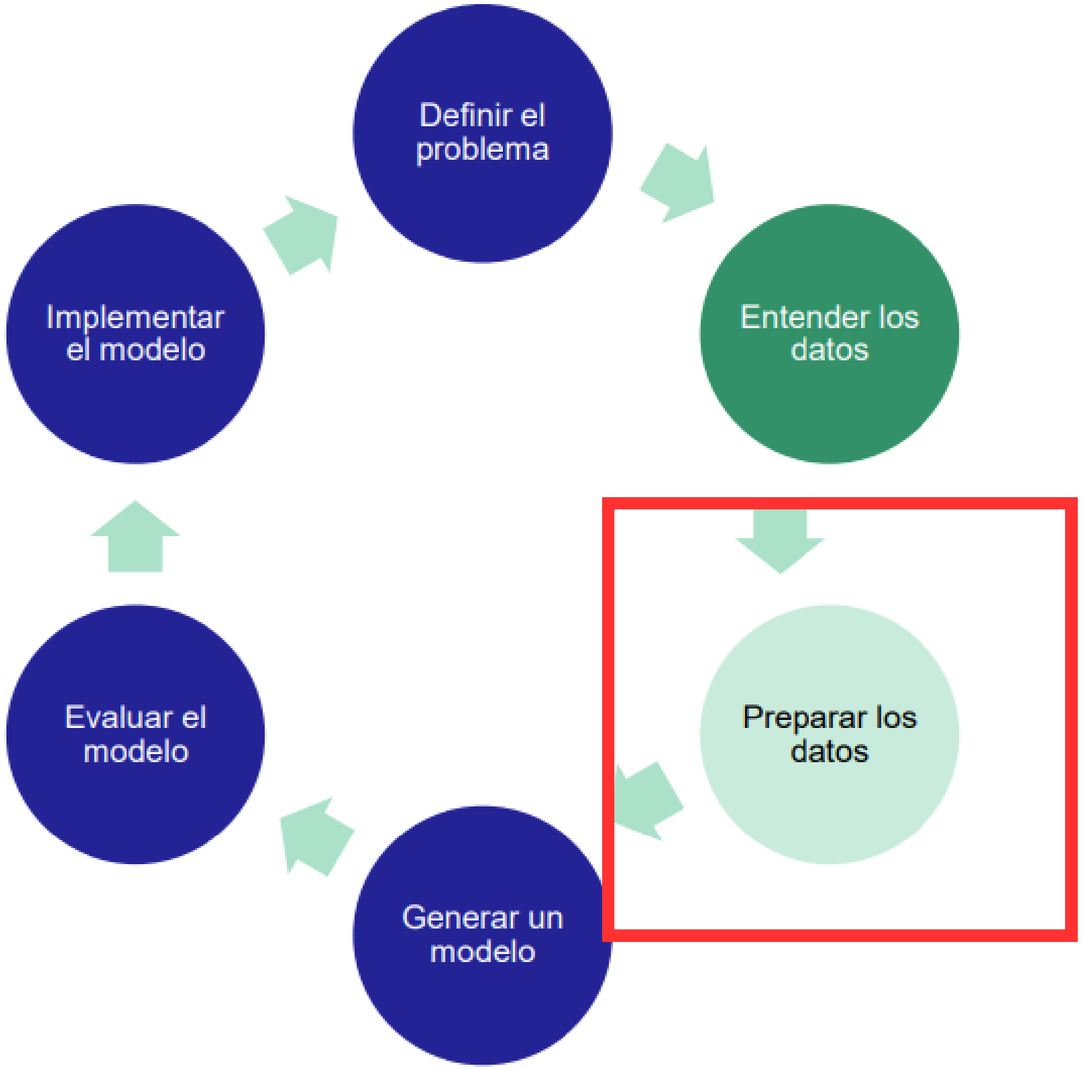


*No es casualidad que los únicos dos círculos que están de distinto color sean estos*

# ¿QUÉ ERRORES BUSCAMOS CUANDO HACEMOS DATA PREPPING?

*¿y como los arreglamos?*

| ID | Edad | Ingreso Mensual | Ciudad |
|---|---|---|---|
| 1 | 25 | 1200 | Buenos Aires |
| 2 | 30 | null | Córdoba |
| 3 | null | 950 | Rosario |
| 4 | 45 | 2000 | null |
| 5 | 38 | 1750 | Mendoza |
| 6 | null | null | La Plata |
| 7 | 29 | 1100 | null |
| 8 | 50 | 3000 | Buenos Aires |
| 9 | null | 800 | Córdoba |
| 10 | 33 | null | Rosario |

## Datos nulos

### ¿Qué buscamos?

Datos nulos, Nan o que de alguna manera no haya información (###, ---, ., Etc)

### ¿Cómo los arreglamos?

## Datos nulos

### ¿Qué buscamos?

Datos nulos, Nan o que de alguna manera no haya información (###, ---, ., Etc)

### ¿Cómo los arreglamos?

- Eliminar filas o columnas con muchos nulos

| ID | Edad | Ingreso Mensual | Ciudad |
|---|---|---|---|
| 1 | 25 | 1200 | Buenos Aires |
| 2 | 30 | null | Córdoba |
| 3 | null | null | Córdoba |
| 4 | 45 | 2000 | null |
| 5 | 38 | 1750 | Mendoza |
| 6 | null | null | La Plata |
| 7 | 29 | 1100 | null |
| 8 | 50 | 3000 | Buenos Aires |
| 9 | null | 800 | Córdoba |
| 10 | 33 | null | Rosario |

## Datos nulos

### ¿Qué buscamos?

Datos nulos, Nan o que de alguna manera no haya información (###, ---, ., Etc)

### ¿Cómo los arreglamos?

- Eliminar filas o columnas con muchos nulos
- Imputar con media, mediana o moda

## Datos nulos

### ¿Qué buscamos?

Datos nulos, Nan o que de alguna manera no haya información (###, ---, ., Etc)

### ¿Cómo los arreglamos?

- Eliminar filas o columnas con muchos nulos
- Imputar con media, mediana o moda
- Imputar por grupos (ej: promedio por ciudad)

## Datos nulos

### ¿Qué buscamos?

Datos nulos, Nan o que de alguna manera no haya información (###, ---, ., Etc)

### ¿Cómo los arreglamos?

- Eliminar filas o columnas con muchos nulos
- Imputar con media, mediana o moda
- Imputar por grupos (ej: promedio por ciudad)
- *Crear categoría “Desconocido” para variables categóricas*
- *Usar métodos avanzados (KNN, MICE, modelos predictivos)*

| ID | Edad | Ingreso Mensual | Ciudad |
|---|---|---|---|
| 1 | 25 | 1200 | Buenos Aires |
| 2 | 30 | 1500 | bs as |
| 3 | 28 | mil | Córdoba |
| 4 | cuarenta | 2000 | ROSARIO |
| 5 | 35 | 1800 | Mendoza |
| 6 | 29 años | 1700 | Cordoba |
| 7 | 41 | $2,500 | Bs As |
| 8 | 33 | 1600 | buenos aires |
| 9 | 27 | 1.4 | Mendoza |
| 10 | -50 | 3000 | MENDOZA |

## Inconsistencias

### ¿Qué buscamos?

Datos sin sentido, o que deberían ser iguales pero se diferencian por un mal ingreso de dato o mala manipulación de la base

### ¿Cómo los arreglamos?

## Inconsistencias

### ¿Qué buscamos?

Datos sin sentido, o que deberían ser iguales pero se diferencian por un mal ingreso de dato o mala manipulación de la base

### ¿Cómo los arreglamos?

De guapo, con código

## Inconsistencias

### ¿Qué buscamos?

Datos sin sentido, o que deberían ser iguales pero se diferencian por un mal ingreso de dato o mala manipulación de la base

### ¿Cómo los arreglamos?

De guapo, con código

No sin antes hacer un buen EDA y encontrar donde está la falla !

**df.unique()** para categorías

| ID | Edad | Ingreso Mensual | Ciudad |
|---|---|---|---|
| 1 | 25 | 1200 | Buenos Aires |
| 2 | 30 | 1500 | bs as |
| 3 | 28 | mil | Córdoba |
| 4 | cuarenta | 2000 | ROSARIO |
| 5 | 35 | 1800 | Mendoza |
| 6 | 29 años | 1700 | Cordoba |
| 7 | 41 | $2,500 | Bs As |
| 8 | 33 | 1600 | buenos aires |
| 9 | 27 | 1.4 | Mendoza |
| 10 | -50 | 3000 | MENDOZA |

## Inconsistencias

### ¿Qué buscamos?

Datos sin sentido, o que deberían ser iguales pero se diferencian por un mal ingreso de dato o mala manipulación de la base

### ¿Cómo los arreglamos?

De guapo, con código

No sin antes hacer un buen EDA y encontrar donde está la falla !

**df.unique()** para categorías

## Ok

Nulos
Inconsistencias
¿Qué más?

| ID | Edad | Ingreso Mensual | Ciudad |
|---|---|---|---|
| 1 | 25 | 1200 | Buenos Aires |
| 2 | 30 | 1500 | Buenos Aires |
| 3 | 28 | 1300 | Rosario |
| 4 | 35 | 1800 | Mendoza |
| 5 | 40 | 2000 | La Plata |
| 6 | 29 | 1700 | Córdoba |
| 7 | 31 | 1600 | Buenos Aires |
| 8 | 27 | 1400 | Rosario |
| 9 | 104 | 1900 | Mendoza |
| 10 | 33 | 150000 | Buenos Aires |

## Outliers

### ¿Qué buscamos?

Datos por fuera del IQR, O que simplemente estén en lados muy extremos de la distribución

### ¿Cómo los arreglamos?

## Outliers

### ¿Qué buscamos?

Datos por fuera del IQR, O que simplemente estén en lados muy extremos de la distribución

### ¿Cómo los arreglamos?

**Eliminar** outliers si son errores
**Mantener** si sirve la información

Hay que analizar los casos particulares y revisar si tiene sentido mantener la info en el dataset

## Outliers

### ¿Qué buscamos?

Datos por fuera del IQR, O que simplemente estén en lados muy extremos de la distribución

### ¿Cómo los arreglamos?

**Eliminar** outliers si son errores
**Mantener** si sirve la información

Hay que analizar los casos particulares y revisar si tiene sentido mantener la info en el dataset

**Disclaimer**: Hay modelos que manejan muy bien los outliers, y otros que si no los tratás te arruinan la carrera

| ID | Edad | Ingreso Mensual | Ciudad |
|---|---|---|---|
| 1 | 25 | 1200 | Buenos Aires |
| 2 | 30 | 1500 | Córdoba |
| 3 | 30 | 1500 | Córdoba |
| 4 | 35 | 1800 | Mendoza |
| 5 | 40 | 2000 | La Plata |
| 6 | 30 | 1500 | Córdoba |
| 7 | 31 | 1600 | Buenos Aires |
| 8 | 28 | 1300 | Rosario |
| 9 | 27 | 1400 | Mendoza |
| 10 | 25 | 1200 | Buenos Aires |

| ID | Edad | Ingreso Mensual | Ciudad |
|---|---|---|---|
| 1 | 25 | 1200 | Buenos Aires |
| 2 | 30 | 1500 | Córdoba |
| 3 | 30 | 1500 | Córdoba |
| 4 | 35 | 1800 | Mendoza |
| 5 | 40 | 2000 | La Plata |
| 6 | 30 | 1500 | Córdoba |
| 7 | 31 | 1600 | Buenos Aires |
| 8 | 28 | 1300 | Rosario |
| 9 | 27 | 1400 | Mendoza |
| 10 | 25 | 1200 | Buenos Aires |

## Duplicados

### ¿Qué buscamos?

Datos con los mismos valores en todas las columnas

### ¿Cómo los arreglamos?

## Duplicados

**¿Qué buscamos?**

Datos con los mismos valores en todas las columnas

**¿Cómo los arreglamos?**

Primero, chequeo si tengo duplicados, y despues los elimino

**df.drop_duplicates()**

| ID | Edad | Ingreso Mensual | Ciudad |
|---|---|---|---|
| 1 | 25 | 1200 | Buenos Aires |
| 2 | 30 | 1500 | Córdoba |
| 3 | 30 | 1500 | Córdoba |
| 4 | 35 | 1800 | Mendoza |
| 5 | 40 | 2000 | La Plata |
| 6 | 30 | 1500 | Córdoba |
| 7 | 31 | 1600 | Buenos Aires |
| 8 | 28 | 1300 | Rosario |
| 9 | 27 | 1400 | Mendoza |
| 10 | 25 | 1200 | Buenos Aires |

| ID | Edad | Ingreso Mensual | Ciudad |
|---|---|---|---|
| 1 | 25 | 1200 | Buenos Aires |
| 2 | 30 | 1500 | Córdoba |
| 3 | 30 | 1500 | Córdoba |
| 4 | 35 | 1800 | Mendoza |
| 5 | 40 | 2000 | La Plata |
| 6 | 30 | 1500 | Córdoba |
| 7 | 31 | 1600 | Buenos Aires |
| 8 | 28 | 1300 | Rosario |
| 9 | 27 | 1400 | Mendoza |
| 10 | 25 | 1200 | Buenos Aires |

| ID | Edad | Ingreso Mensual | Ciudad |
|---|---|---|---|
| 1 | 25 | 1200 | Buenos Aires |
| 2 | 30 | 1500 | Córdoba |
| 2 | 30 | 1500 | Córdoba |
| 4 | 35 | 1800 | Mendoza |
| 5 | 40 | 2000 | La Plata |
| 6 | 30 | 1500 | Córdoba |
| 7 | 31 | 1600 | Buenos Aires |
| 8 | 28 | 1300 | Rosario |
| 9 | 27 | 1400 | Mendoza |
| 10 | 25 | 1200 | Buenos Aires |

## Otros ejemplos

- Datos irrelevantes (columnas que no aportan valor)
- Datos mal representados (feature engineering pobre)
- Desbalance de clases
- Data leakage (información del futuro o del target)
- Datos desactualizados
- Problemas de integración (múltiples fuentes inconsistentes)
- Granularidad inconsistente (distintos niveles de detalle)

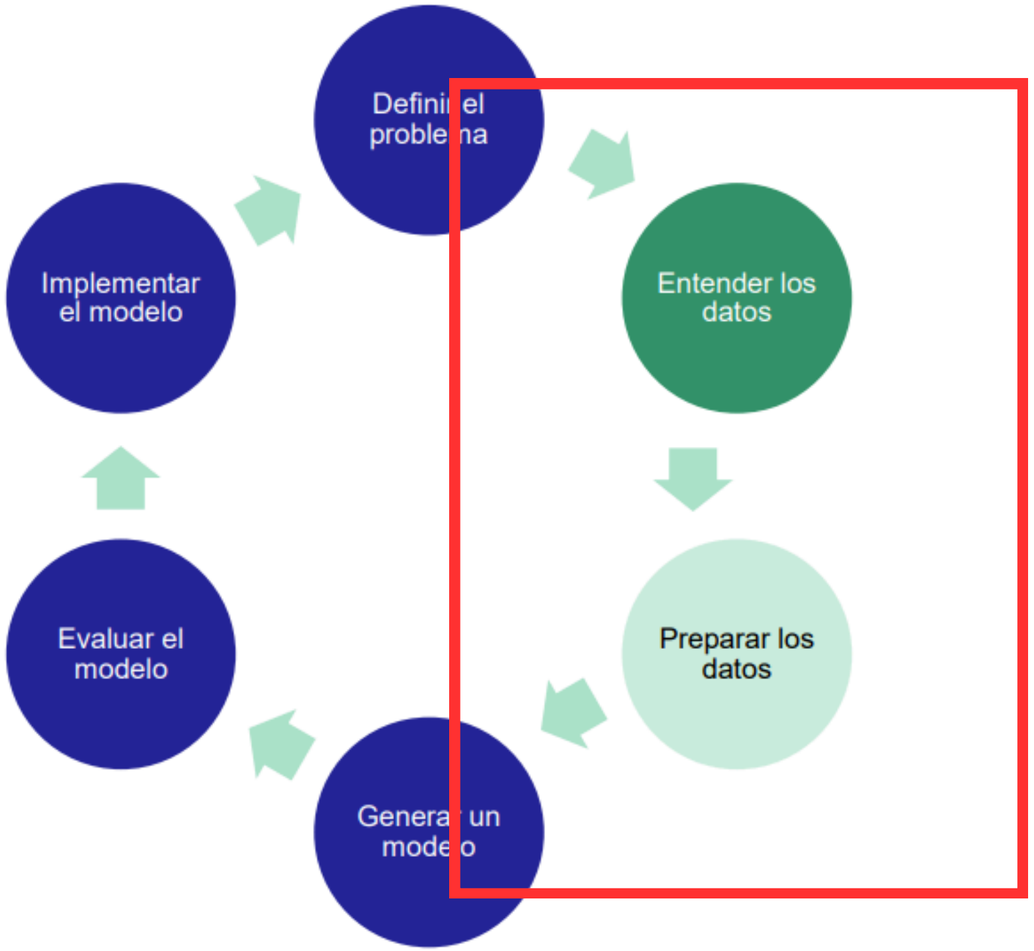
Definir el problema
Entender los datos
Preparar los datos
Generar un modelo
Evaluar el modelo
Implementar el modelo

# Notebook 10 Minutos

# Programa

| | Modulo |
|---|---|
| 1 | Analítica de Datos y las organizaciones ✓ |
| 2 | Aprendizaje Automático Supervisado |
| 3 | Aprendizaje Automático No Supervisado |
| 4 | Deep Learning (!!!) |

**Muy bueno,**

**MaCHINE learning**

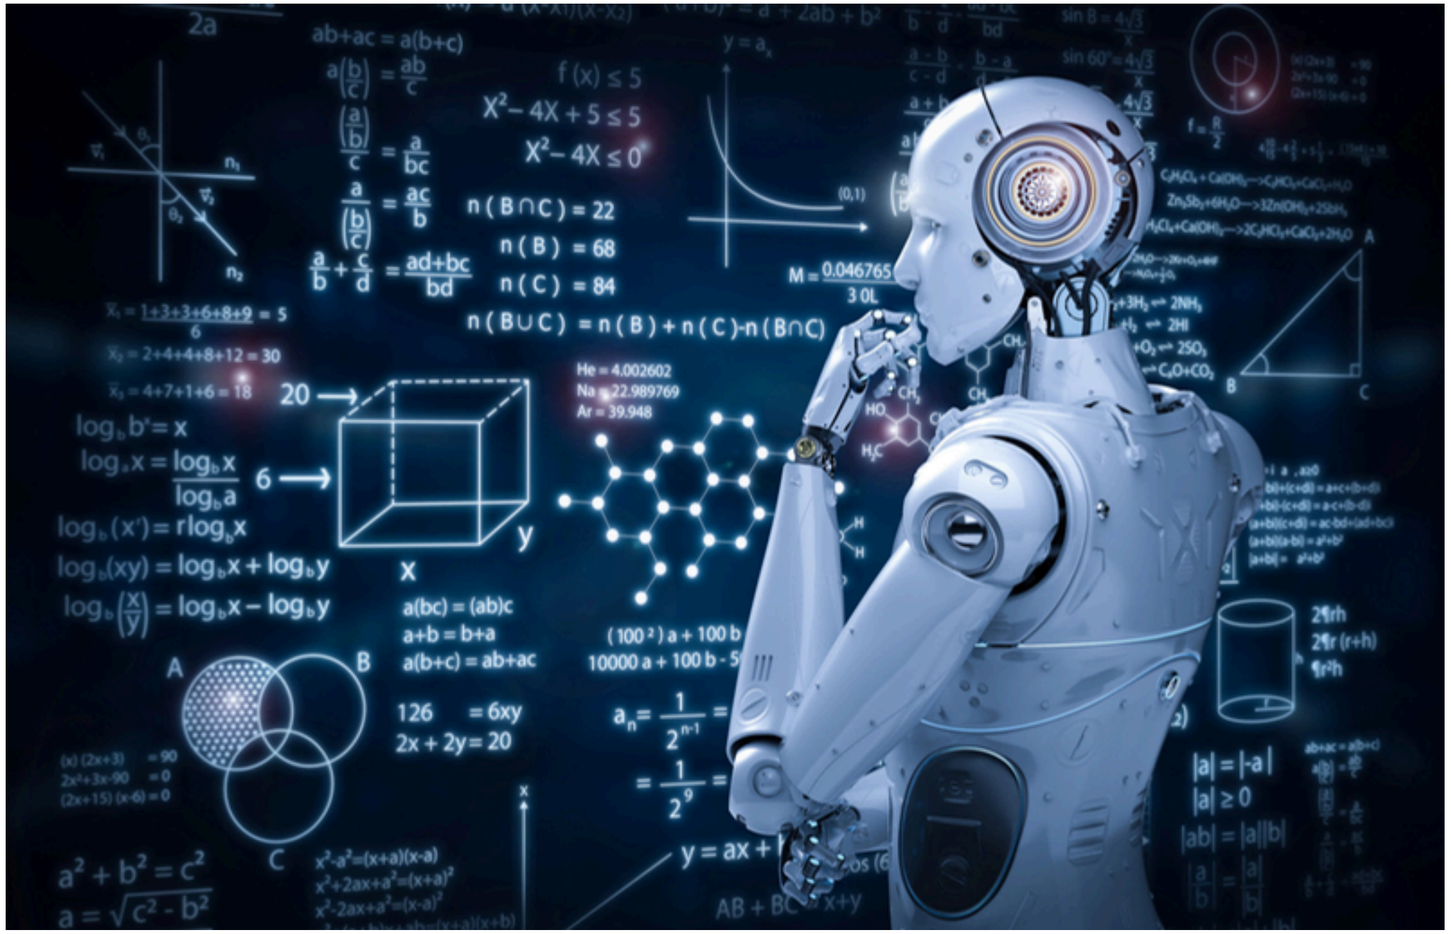

# Machine Learning

*¿Qué es el Machine Learning?*

# Machine Learning

*¿Qué es el Machine Learning?*

Rama qué permite a las computadoras aprender patrones a partir de datos y hacer predicciones o decisiones sin ser programadas explícitamente para cada caso.

*¿Qué tipos de Modelos de Machine Learning existen?*

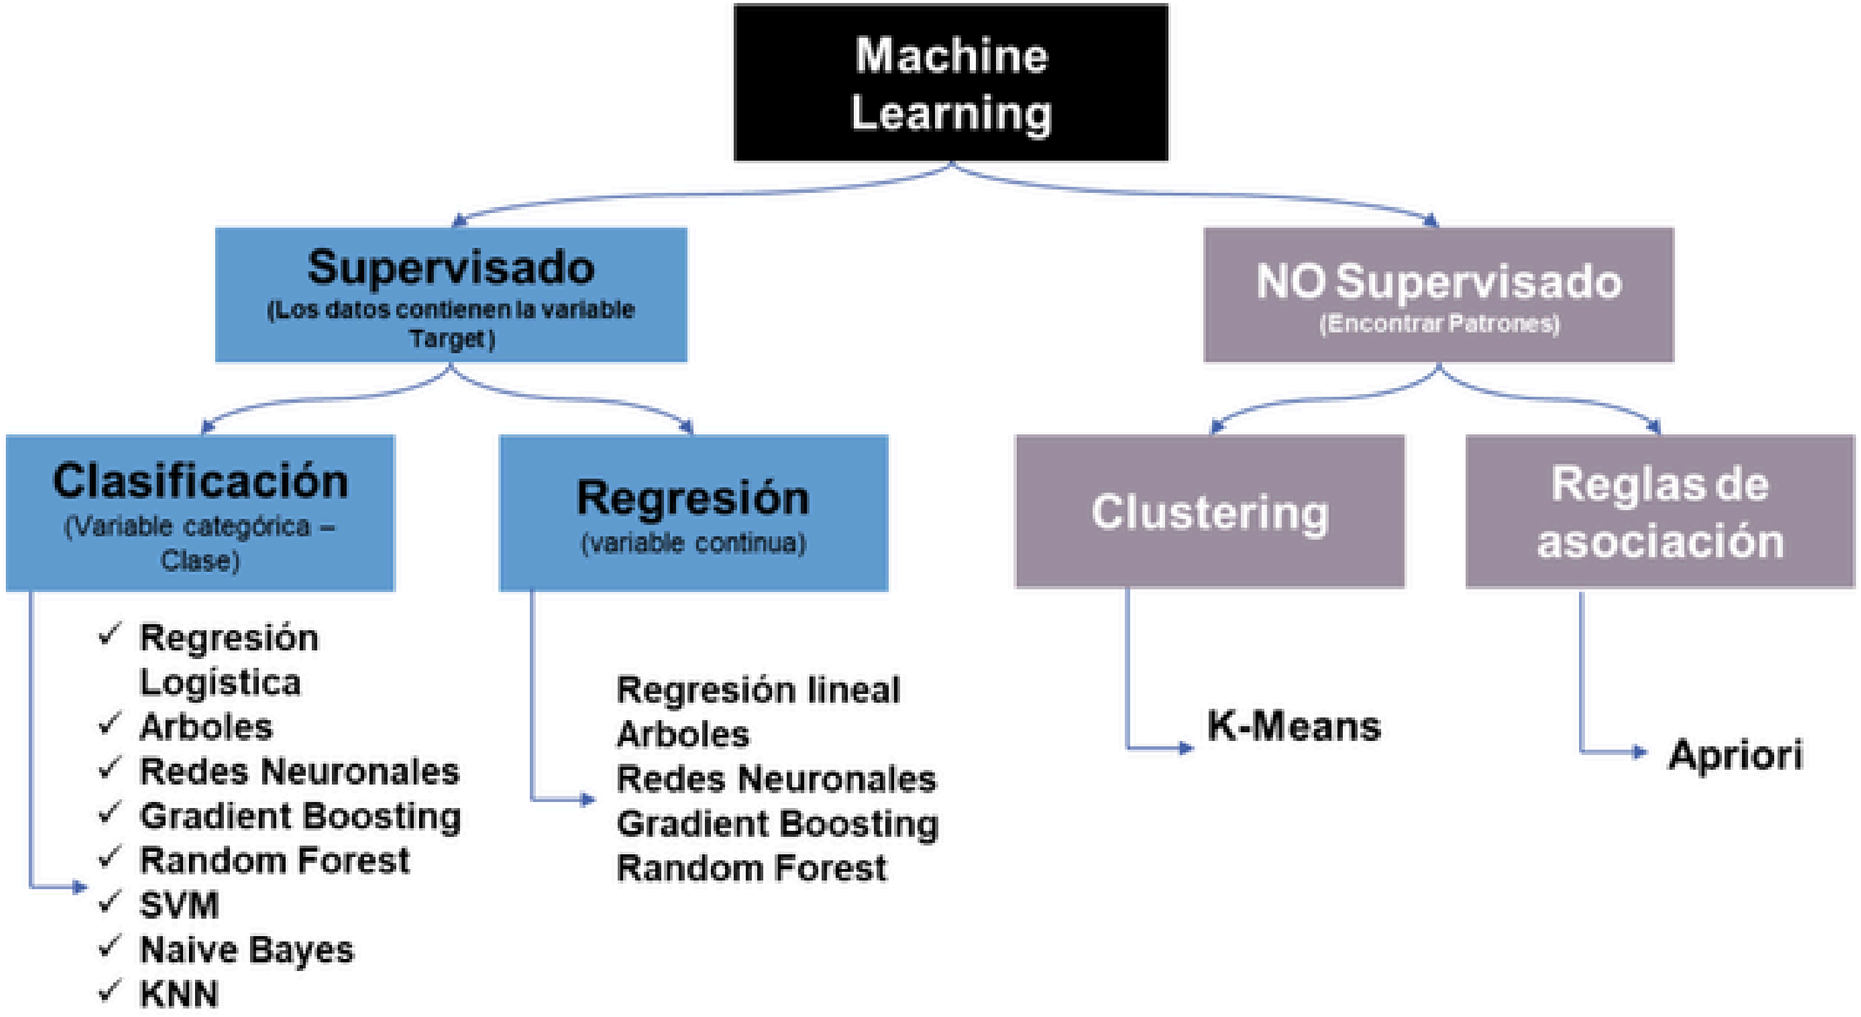
Machine Learning
Supervisado
(Los datos contienen la variable Target)
NO Supervisado
(Encontrar Patrones)
Clasificación
(Variable categórica – Clase)
Regresión
(variable continua)
Clustering
Reglas de asociación
✓ Regresión Logística
✓ Arboles
✓ Redes Neuronales
✓ Gradient Boosting
✓ Random Forest
✓ SVM
✓ Naive Bayes
✓ KNN
Regresión lineal
Arboles
Redes Neuronales
Gradient Boosting
Random Forest
K-Means
Apriori

# Programa

| | Modulo |
|---|---|
| 1 | Analítica de Datos y las organizaciones |
| 2 | Aprendizaje Automático Supervisado |
| 3 | Aprendizaje Automático No Supervisado |
| 4 | Deep Learning (!!!) |

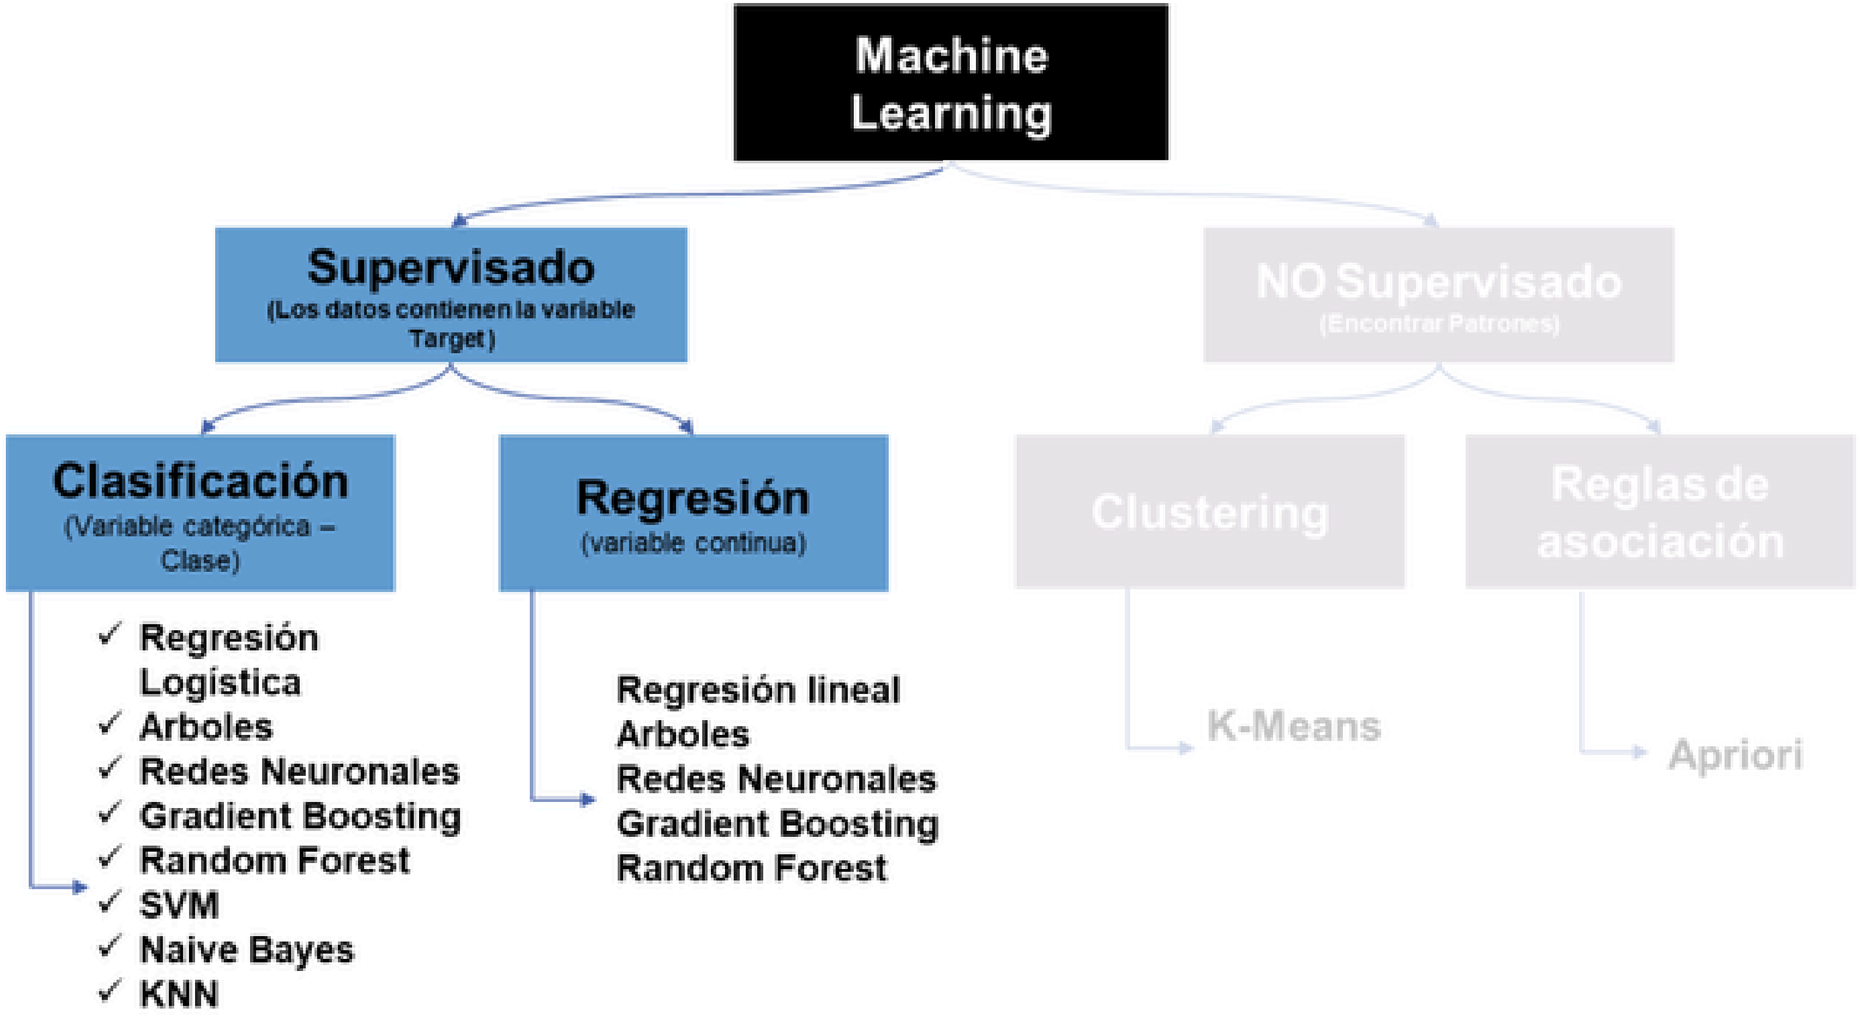
Machine Learning
Supervisado
(Los datos contienen la variable Target)
NO Supervisado
(Encontrar Patrones)
Clasificación
(Variable categórica – Clase)
Regresión
(variable continua)
Clustering
Reglas de asociación
✓ Regresión Logística
✓ Arboles
✓ Redes Neuronales
✓ Gradient Boosting
✓ Random Forest
✓ SVM
✓ Naive Bayes
✓ KNN
Regresión lineal
Arboles
Redes Neuronales
Gradient Boosting
Random Forest
K-Means
Apriori

# Machine Learning

*¿Qué es el Machine Learning?*

Rama qué permite a las computadoras aprender patrones a partir de datos y hacer predicciones o decisiones sin ser programadas explícitamente para cada caso.

*¿Qué tipos de Modelos de Machine Learning existen?*

**Supervisados**: los datos tienen una variable **TARGET** que funciona para predecir
**No supervisados**: los datos no tienen una variable **TARGET**

# Machine Learning

*Ejercicio, ¿Estos casos son supervisados o no supervisado?*

- Un modelo que usa datos históricos de casas con su precio para predecir cuánto vale una casa nueva
- Un algoritmo que agrupa clientes según su comportamiento de compra
- Un sistema que aprende a clasificar emails como “spam” o “no spam” usando ejemplos etiquetados
- Un modelo que analiza transacciones y detecta patrones raros sin saber previamente cuáles son fraude

# Machine Learning

*Ejercicio, ¿Estos casos son supervisados o no supervisado?*

- Un modelo que usa datos históricos de casas con su precio para predecir cuánto vale una casa nueva **SUPERVISADO**
- Un algoritmo que agrupa clientes según su comportamiento de compra
- Un sistema que aprende a clasificar emails como “spam” o “no spam” usando ejemplos etiquetados
- Un modelo que analiza transacciones y detecta patrones raros sin saber previamente cuáles son fraude

# Machine Learning

*Ejercicio, ¿Estos casos son supervisados o no supervisado?*

- Un modelo que usa datos históricos de casas con su precio para predecir cuánto vale una casa nueva **SUPERVISADO**
- Un algoritmo que agrupa clientes según su comportamiento de compra **NO SUPERVISADO**
- Un sistema que aprende a clasificar emails como “spam” o “no spam” usando ejemplos etiquetados
- Un modelo que analiza transacciones y detecta patrones raros sin saber previamente cuáles son fraude

# Machine Learning

*Ejercicio, ¿Estos casos son supervisados o no supervisado?*

- Un modelo que usa datos históricos de casas con su precio para predecir cuánto vale una casa nueva **SUPERVISADO**
- Un algoritmo que agrupa clientes según su comportamiento de compra **NO SUPERVISADO**
- Un sistema que aprende a clasificar emails como “spam” o “no spam” usando ejemplos etiquetados **SUPERVISADO**
- Un modelo que analiza transacciones y detecta patrones raros sin saber previamente cuáles son fraude

# Machine Learning

*Ejercicio, ¿Estos casos son supervisados o no supervisado?*

- Un modelo que usa datos históricos de casas con su precio para predecir cuánto vale una casa nueva **SUPERVISADO**
- Un algoritmo que agrupa clientes según su comportamiento de compra **NO SUPERVISADO**
- Un sistema que aprende a clasificar emails como “spam” o “no spam” usando ejemplos etiquetados **SUPERVISADO**
- Un modelo que analiza transacciones y detecta patrones raros sin saber previamente cuáles son fraude **NO SUPERVISADO**

# Machine Learning

*¿Qué es un modelo?*

Un modelo es una función que aprende patrones de los datos para hacer predicciones.

*¿Qué tipos de modelos supervisados hay?*

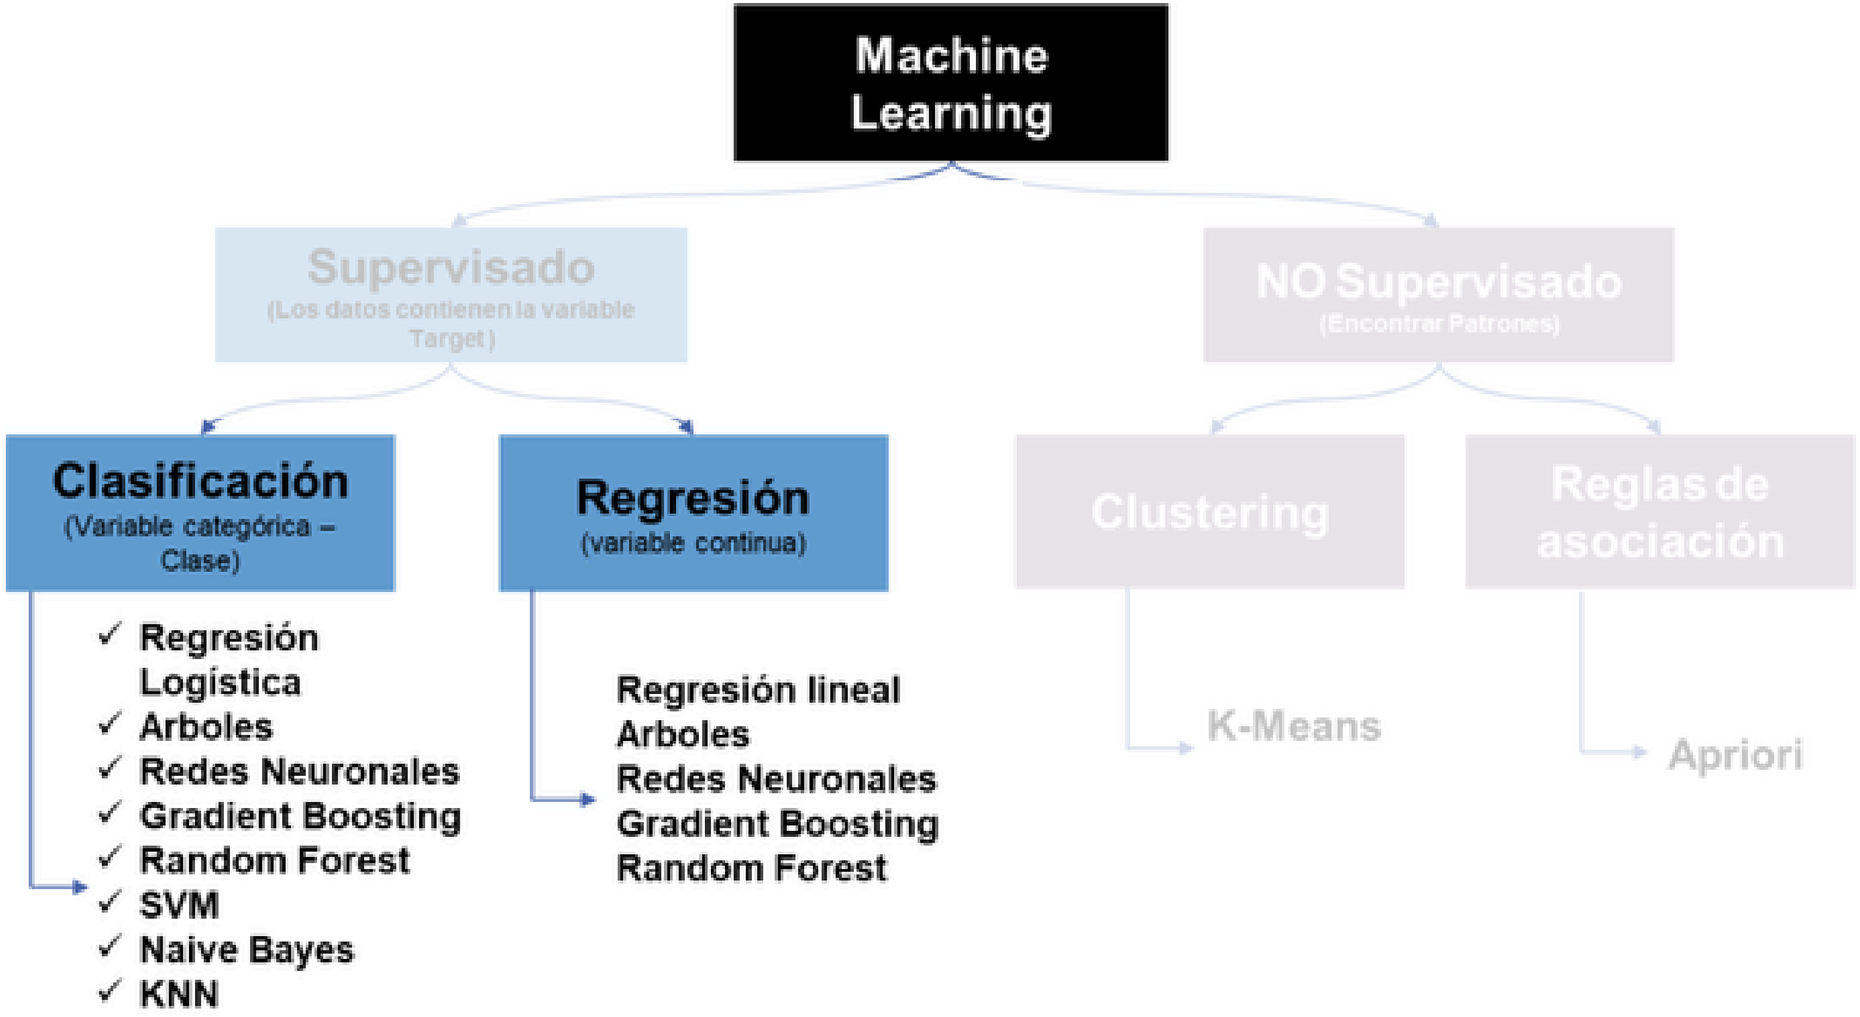
Machine Learning
Supervisado
(Los datos contienen la variable Target)
NO Supervisado
(Encontrar Patrones)
Clasificación
(Variable categórica – Clase)
Regresión
(variable continua)
Clustering
Reglas de asociación
✓ Regresión Logística
✓ Arboles
✓ Redes Neuronales
✓ Gradient Boosting
✓ Random Forest
✓ SVM
✓ Naive Bayes
✓ KNN
Regresión lineal
Arboles
Redes Neuronales
Gradient Boosting
Random Forest
K-Means
Apriori

# Machine Learning

*¿Qué es un modelo?*

Un modelo es una función que aprende patrones de los datos para hacer predicciones.

*¿Qué tipos de modelos supervisados hay?*

**Clasificación**: Buscan predecir una categoría
**Regresión**: Buscan predecir un número

# Machine Learning

*Ejercicio, ¿Estos casos son clasificación o regresión?*

- Predecir el precio de una casa en función de sus características
- Determinar si un email es “spam” o “no spam”
- Estimar la cantidad de ventas de un producto el próximo mes
- Predecir si un cliente va a abandonar, mantener o mejorar un servicio

# Machine Learning

*Ejercicio, ¿Estos casos son clasificación o regresión?*

- Predecir el precio de una casa en función de sus características **REGRESIÓN**
- Determinar si un email es “spam” o “no spam”
- Estimar la cantidad de ventas de un producto el próximo mes
- Predecir si un cliente va a abandonar, mantener o mejorar un servicio

# Machine Learning

*Ejercicio, ¿Estos casos son clasificación o regresión?*

- Predecir el precio de una casa en función de sus características **REGRESIÓN**
- Determinar si un email es “spam” o “no spam” **CLASIFICACIÓN**
- Estimar la cantidad de ventas de un producto el próximo mes
- Predecir si un cliente va a abandonar, mantener o mejorar un servicio

# Machine Learning

*Ejercicio, ¿Estos casos son clasificación o regresión?*

- Predecir el precio de una casa en función de sus características **REGRESIÓN**
- Determinar si un email es “spam” o “no spam” **CLASIFICACIÓN**
- Estimar la cantidad de ventas de un producto el próximo mes **REGRESIÓN**
- Predecir si un cliente va a abandonar, mantener o mejorar un servicio

# Machine Learning

*Ejercicio, ¿Estos casos son clasificación o regresión?*

- Predecir el precio de una casa en función de sus características **REGRESIÓN**
- Determinar si un email es “spam” o “no spam” **CLASIFICACIÓN**
- Estimar la cantidad de ventas de un producto el próximo mes **REGRESIÓN**
- Predecir si un cliente va a abandonar, mantener o mejorar un servicio **CLASIFICACIÓN**

# Machine Learning

*¿Qué aprendimos?*

¿Qué es **Machine Learning**?
¿Cual es la diferencia entre **supervisado** y no **supervisado**?
¿Qué es un **modelo**?
¿Cual es la diferencia entre **regresión** y **clasificación**?

# Machine Learning

*¿Qué aprendimos?*

¿Qué es **Machine Learning**?
¿Cual es la diferencia entre **supervisado** y no **supervisado**?
¿Qué es un **modelo**?
¿Cual es la diferencia entre **regresión** y **clasificación**?

Una cosa más y pasamos a nuestro primer modelo, **regresión lineal**

# Machine Learning | Overfitting vs Underfitting

Nosotros somos un área de IA de un hospital, y desarrollamos un modelo de predicción para predecir ausentismo en turnos médicos.

Usamos datos de Enero a Marzo para entrenar el modelo y vemos que funciona excelente, acierta el 80% de las veces.

Pero despues volvimos a testear el modelo en Agosto, y el mismo modelo funcionó muy mal, acertando el 60% de las veces.

**¿Por qué pasa esto?**

## Machine Learning | Overfitting vs Underfitting

**Overfitting**: El modelo aprende demasiado los datos de entrenamiento, incluyendo ruido y detalles irrelevantes.

Resultado: No generaliza

- Muy buen rendimiento en entrenamiento
- Mal rendimiento en datos nuevos

**Underfitting**: El modelo aprende muy poco y no captura los patrones importantes.

Resultado: Es demasiado simple

- Mal rendimiento en entrenamiento
- Mal rendimiento en datos nuevos

# Machine Learning | Overfitting vs Underfitting

**Overfitting**: Aprende demasiado
**Underfitting**: Aprende muy poco

***El objetivo es encontrar un equilibrio***

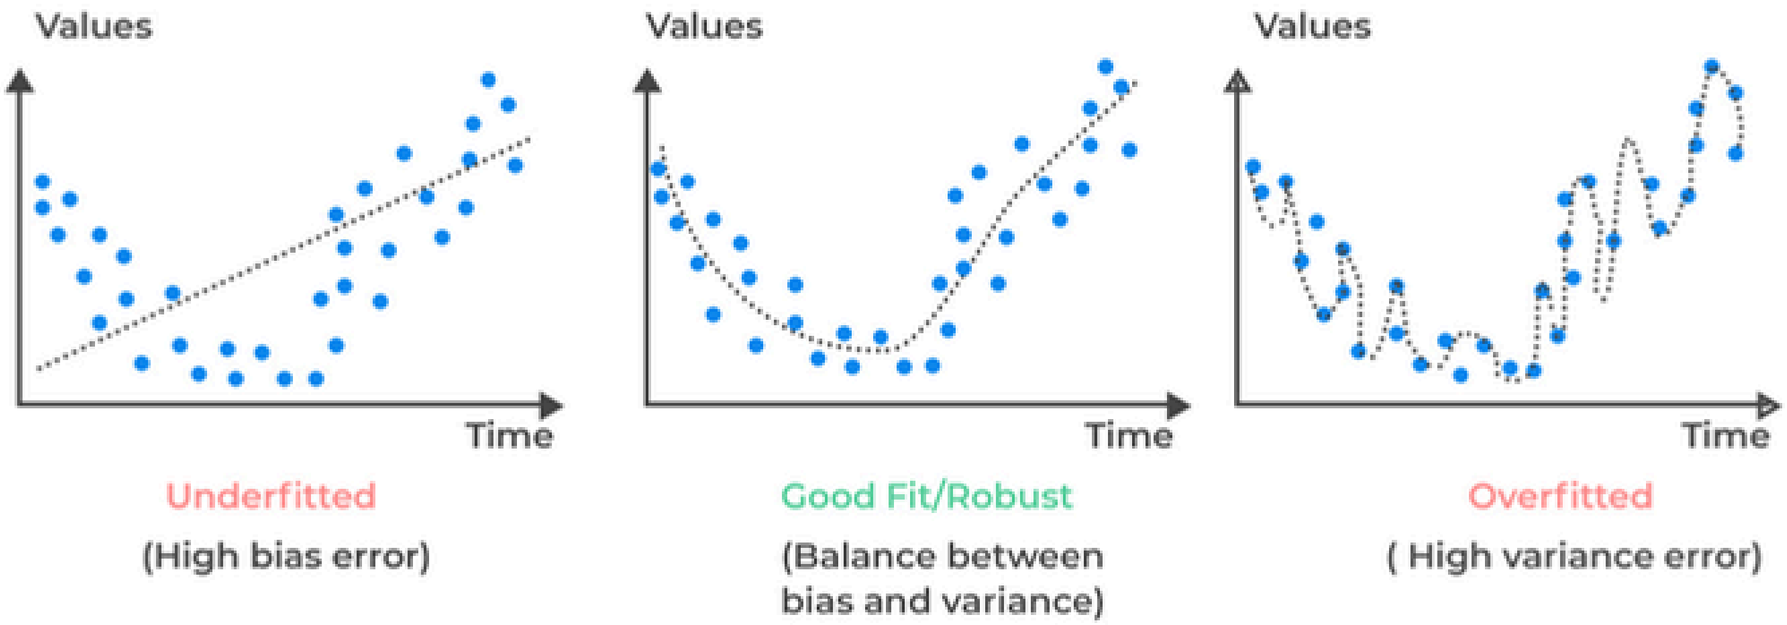

# Machine Learning

*¿Qué aprendimos?*

¿Qué es **Machine Learning**?
¿Cual es la diferencia entre **supervisado** y no **supervisado**?
¿Qué es un **modelo**?
¿Cual es la diferencia entre **regresión** y **clasificación**?
¿Qué es el **overfitting** y **underfitting**?

# Machine Learning

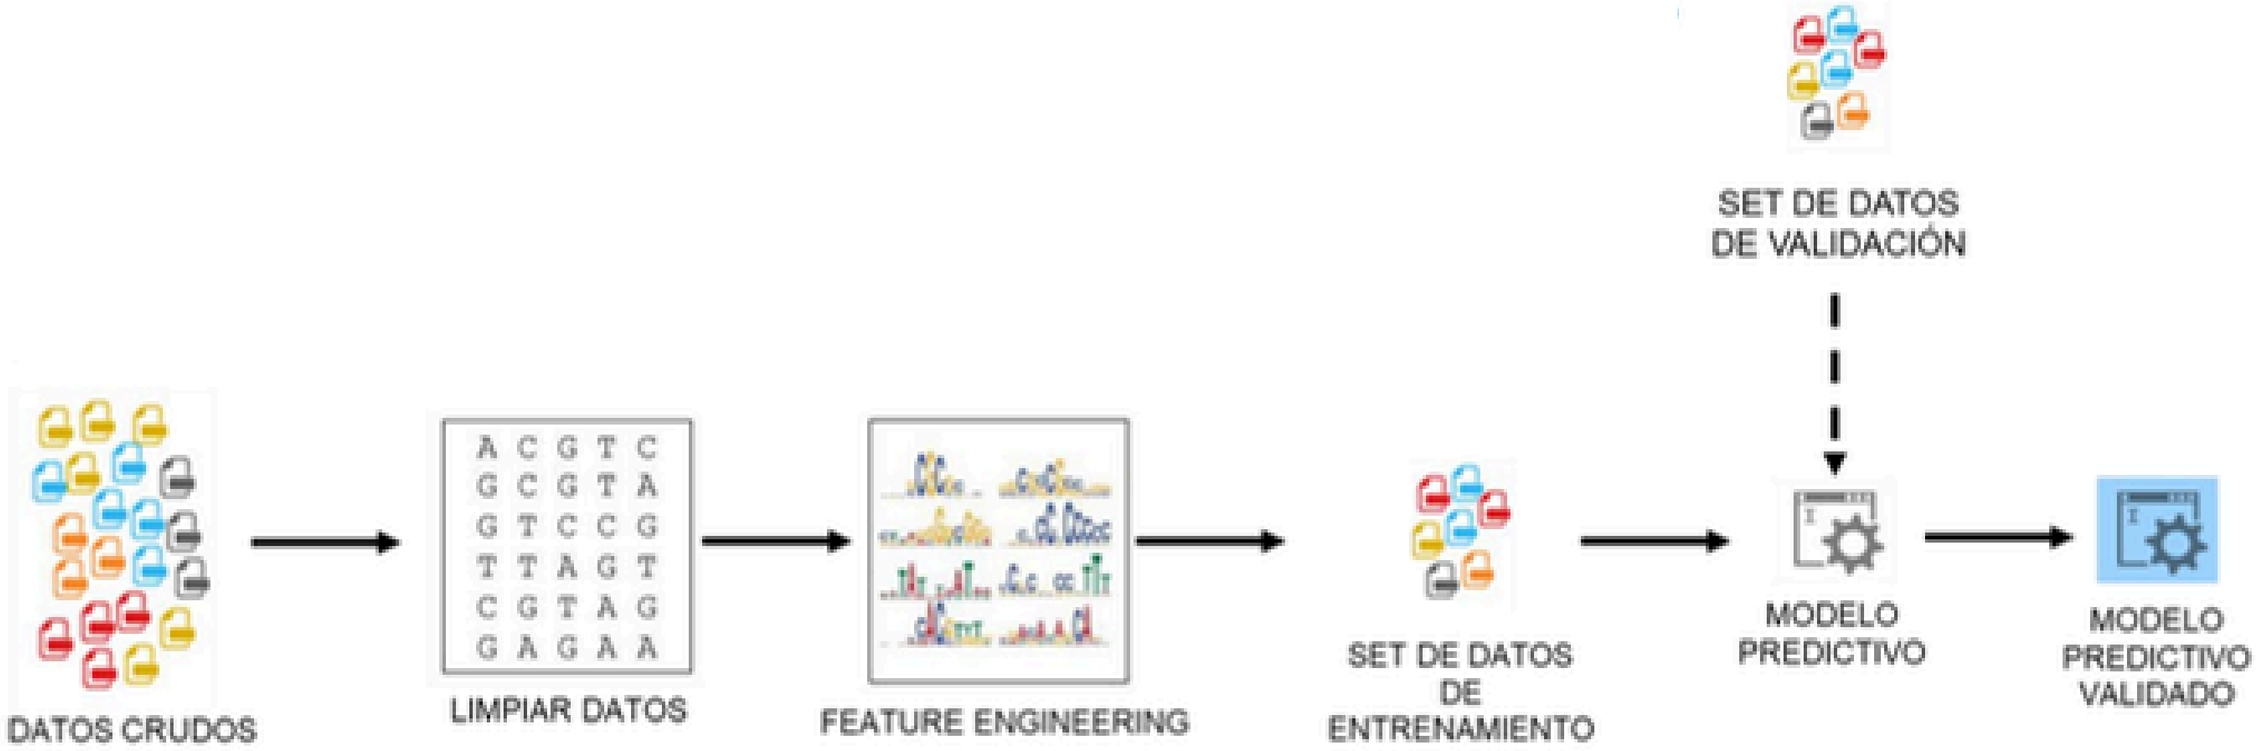

# Machine Learning

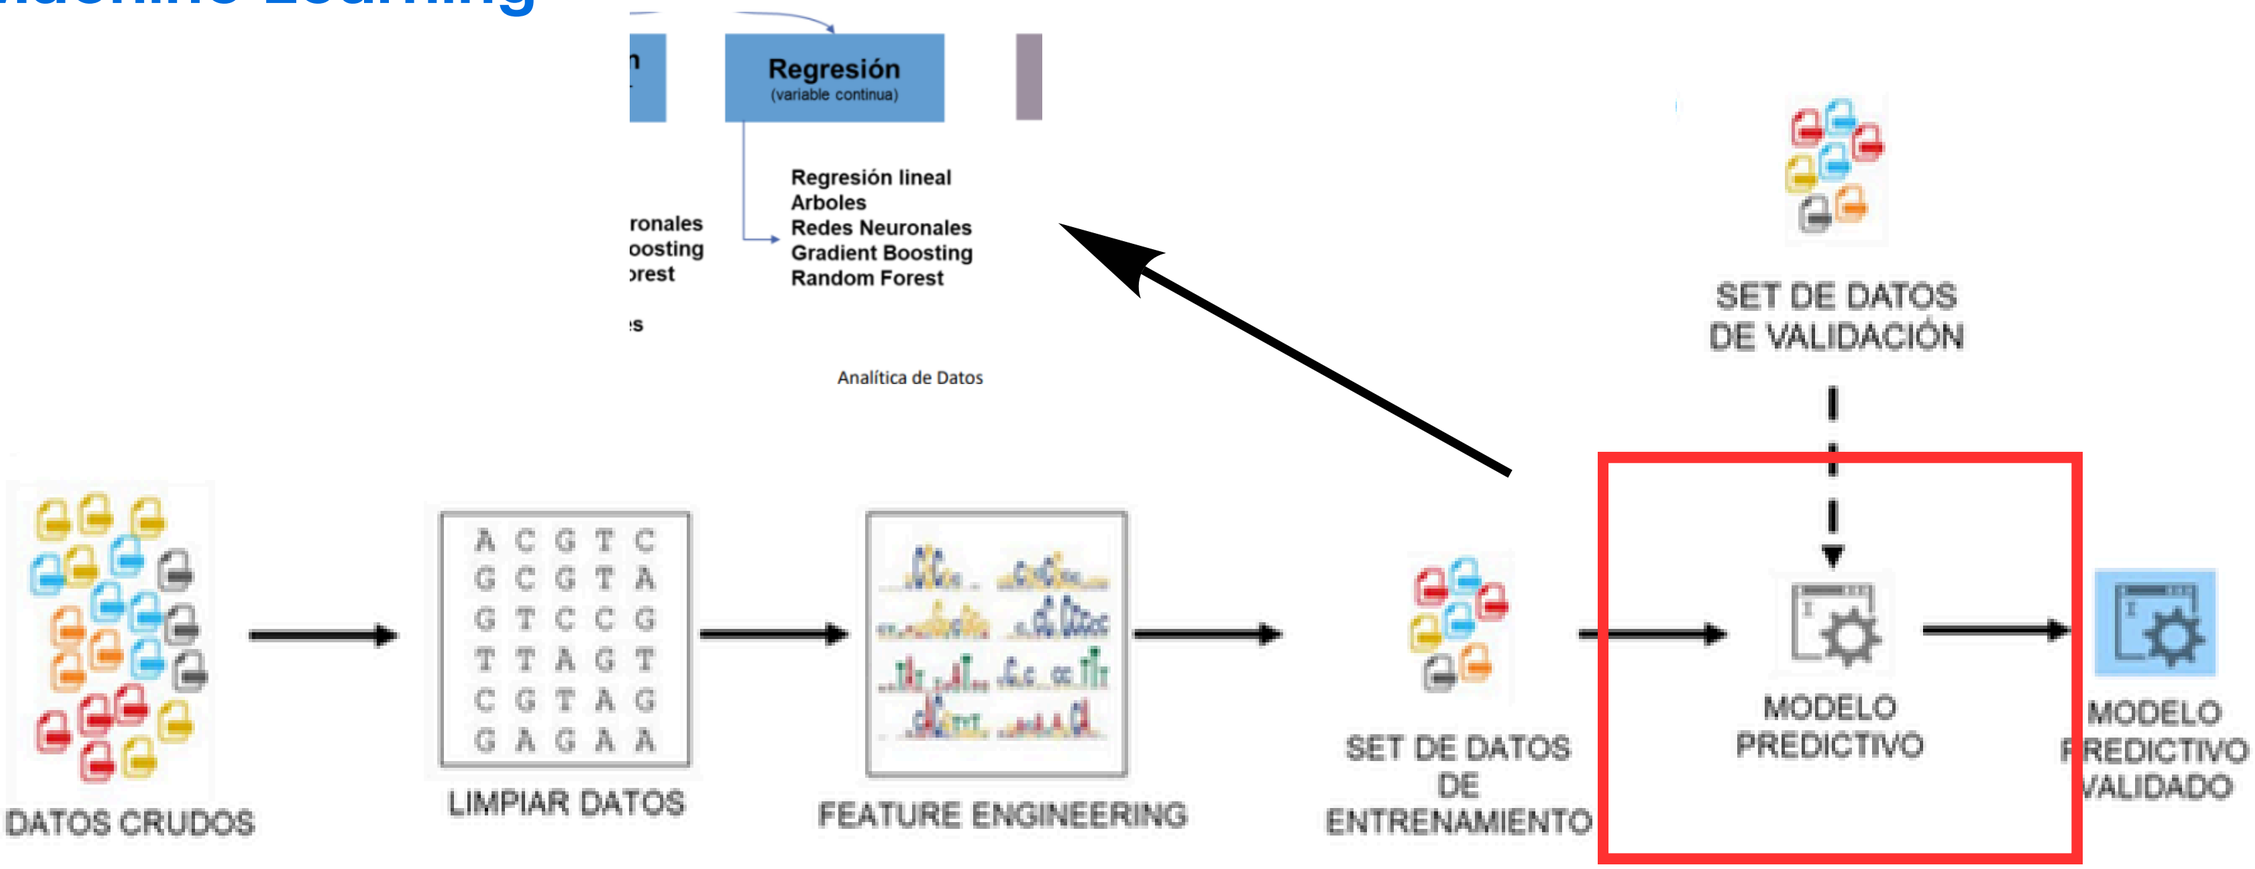

# Regresión Lineal

## ¿Qué es la regresión lineal?

Un modelo que intenta predecir un valor numérico usando una relación lineal entre variables.

# Regresión Lineal

## ¿Qué es la regresión lineal?

Un modelo que intenta predecir un valor numérico usando una relación lineal entre variables.

## Idea intuitiva

Busca dibujar una línea que mejor se ajuste a los datos.

# Regresión Lineal

## ¿Qué es la regresión lineal?

Un modelo que intenta predecir un valor numérico usando una relación lineal entre variables.

## Idea intuitiva

Busca dibujar una línea que mejor se ajuste a los datos.

## ¿Cómo aprende? Machine LEARNING

Ajusta la línea para minimizar el error entre:

- valores reales
- valores predichos

# Regresión Lineal

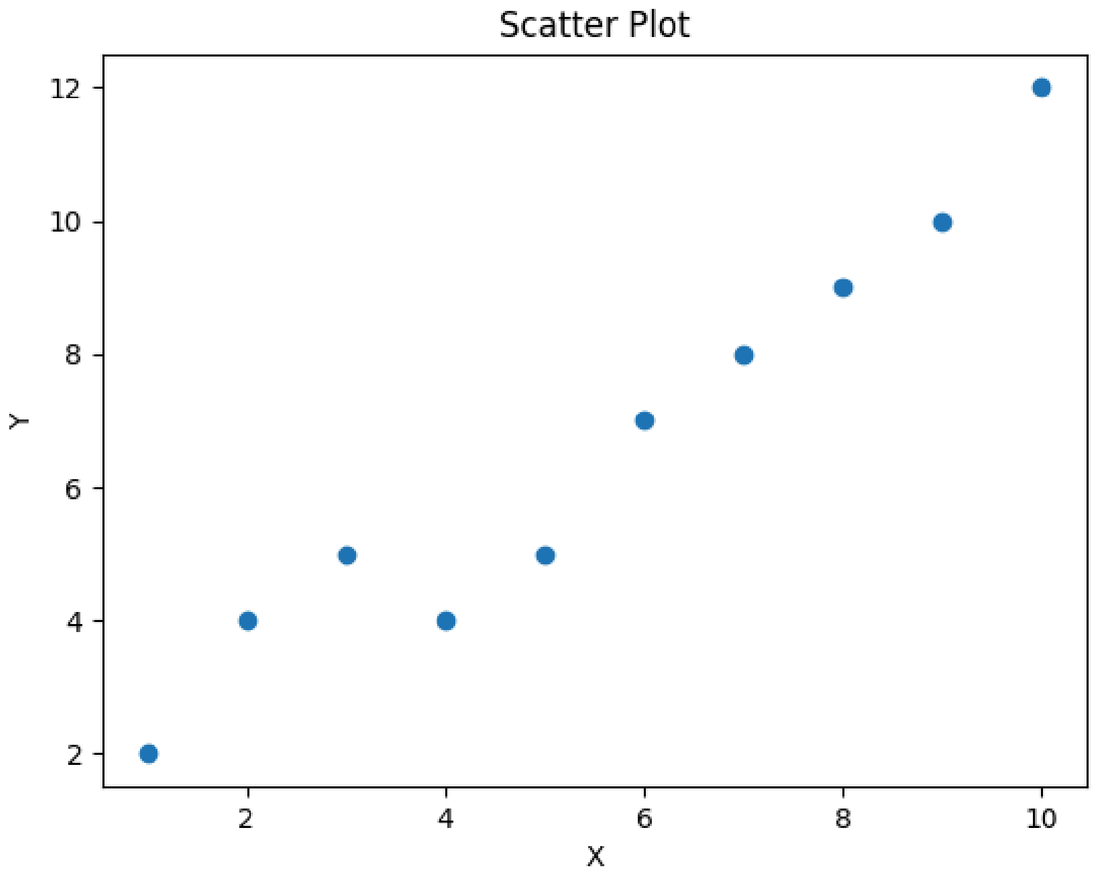

# Regresión Lineal

¿Que podría representar este gráfico?

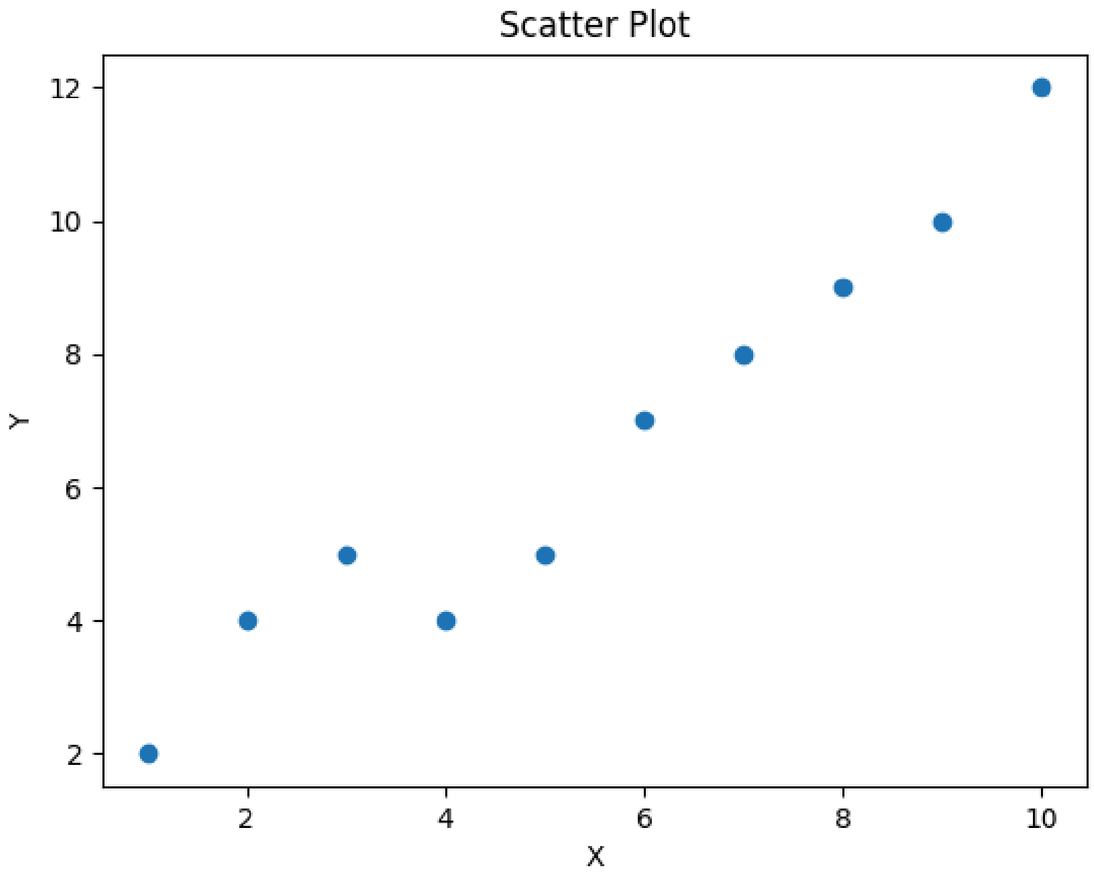

# Regresión Lineal

**¿Que podría representar este gráfico?**

**X:** Años de experiencia laboral

**Y:** Salario (en millones)

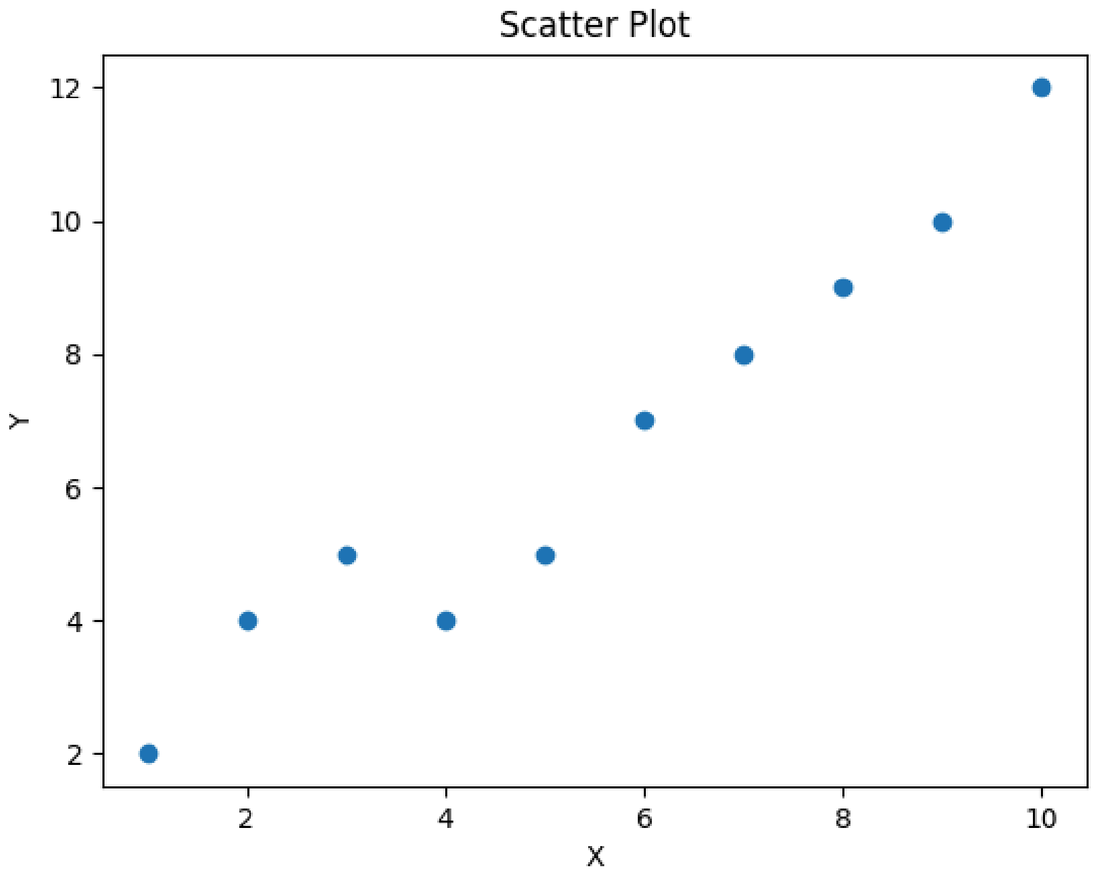

# Regresión Lineal

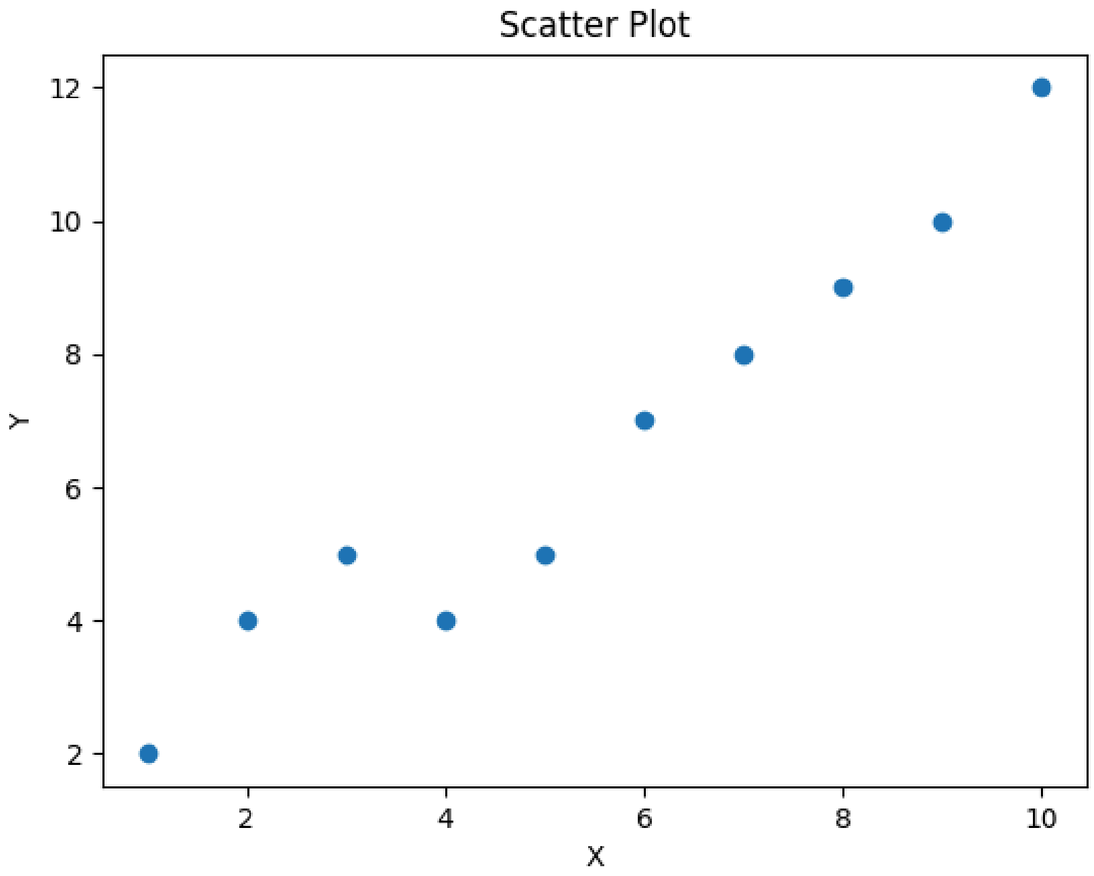


$$\boldsymbol{y} = m \,.\, \boldsymbol{x} + b$$

# Regresión Lineal

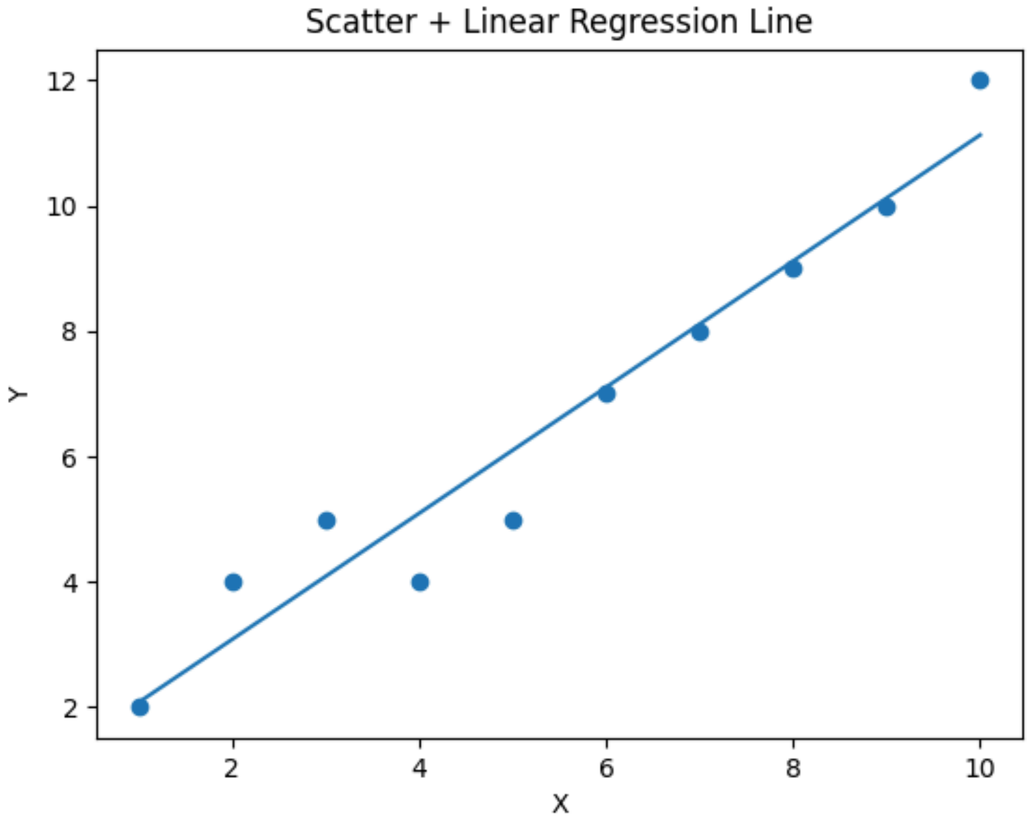


$$\boldsymbol{y} = m \,.\, \boldsymbol{x} + b$$

# Regresión Lineal

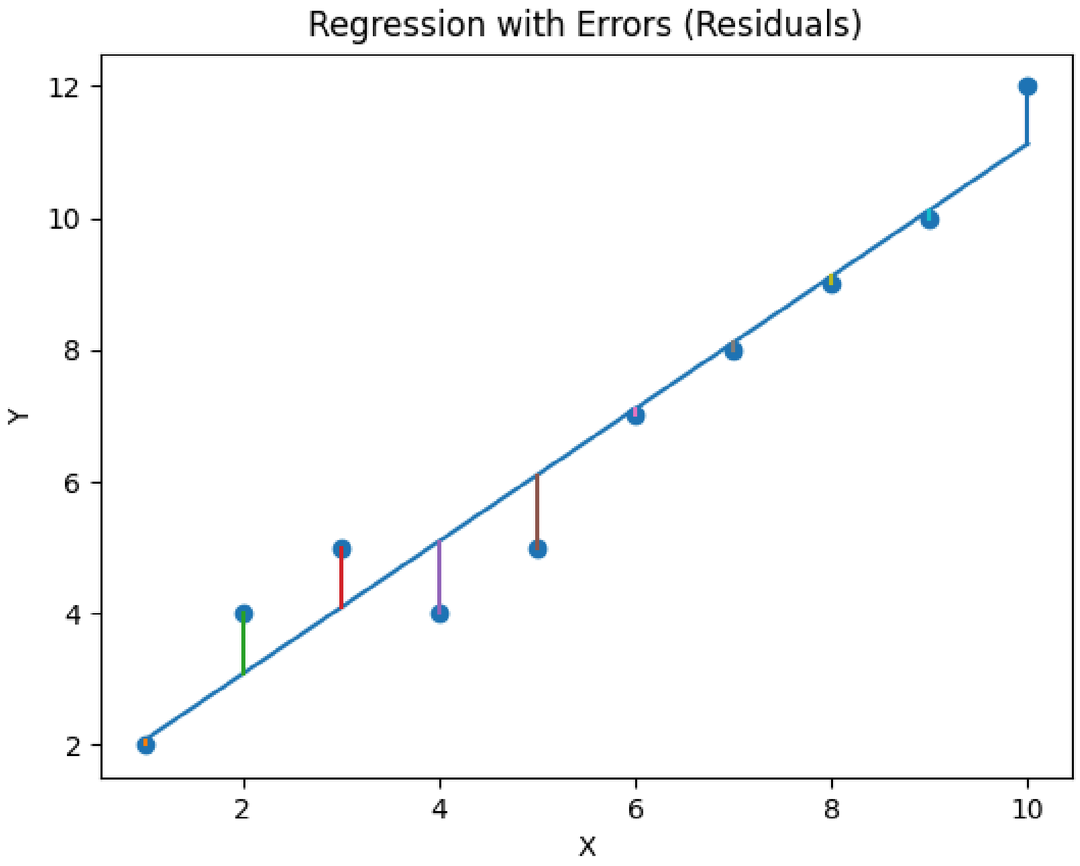


$$\boldsymbol{y} = m \,.\, \boldsymbol{x} + b$$

# Regresión Lineal

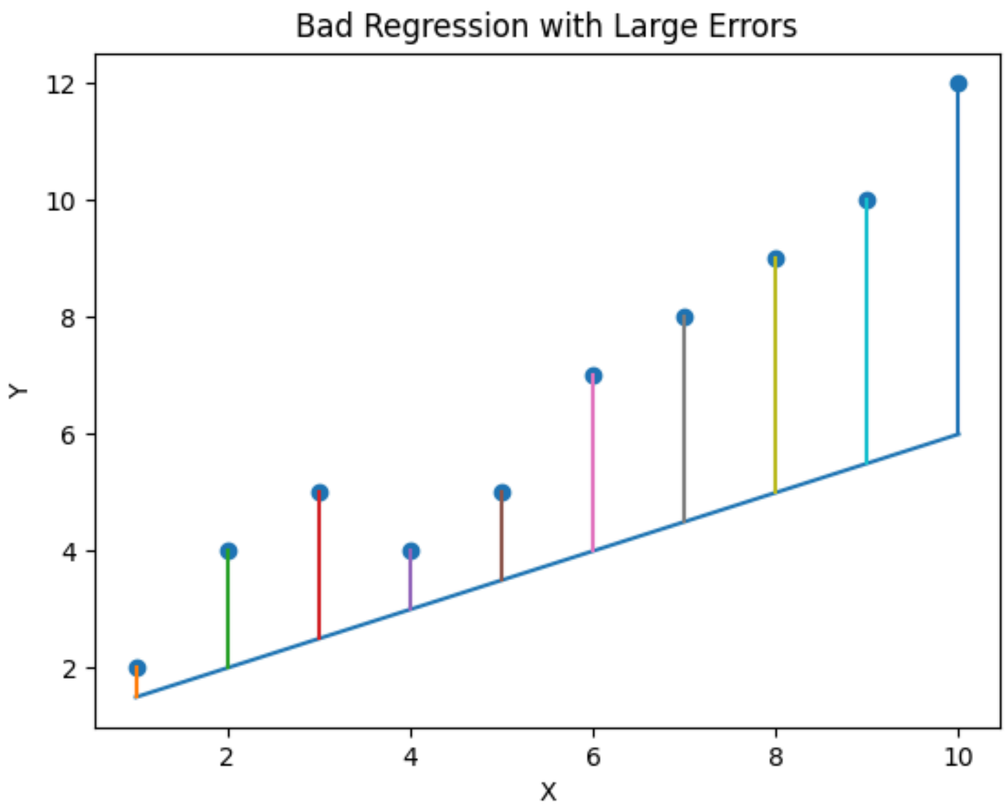


$$\boldsymbol{y} = m \,.\, \boldsymbol{x} + b$$

# Regresión Lineal

**Ejemplos**

Años de experiencia vs salario
Más experiencia → mayor salario (relación positiva)

Horas estudiadas vs nota del examen
Más horas → mejor nota (positiva)

Temperatura vs consumo de calefacción
Más temperatura → menos calefacción (negativa)

Velocidad vs tiempo de viaje (misma distancia)
Más velocidad → menos tiempo (negativa)

# Regresión Lineal

**Ejemplos**

¿Otros ejemplos?

# Regresión Lineal

**Supuestos (muy simple)**

- Relación aproximadamente lineal
- No mucho ruido extremo (outliers afectan)

**Ventajas**

- Fácil de entender
- Rápido
- Buen baseline

**Limitaciones**

- Solo captura relaciones lineales
- Sensible a outliers
- Puede quedarse corto en problemas complejos

# Regresión Lineal

**Supuestos (muy simple)**

- Relación aproximadamente lineal
- No mucho ruido extremo (outliers afectan)

**Ventajas**

- Fácil de entender
- Rápido
- Buen baseline

**Limitaciones**

- Solo captura relaciones lineales
- Sensible a outliers
- Puede quedarse corto en problemas complejos

**¿Cómo funciona el LEARNING, dentro de MACHINE LEARNING?**

Qué ahora el modelo aprendió como se comportan los datos, entonces cuando ingresemos un dato nuevo con un valor *x* y no conozcamos la *y*, lo vamos a poder predecir (o intentar).

En el caso de la regresión lineal, se situa el valor numérico sobre la linea de regresión

# Regresión Lineal

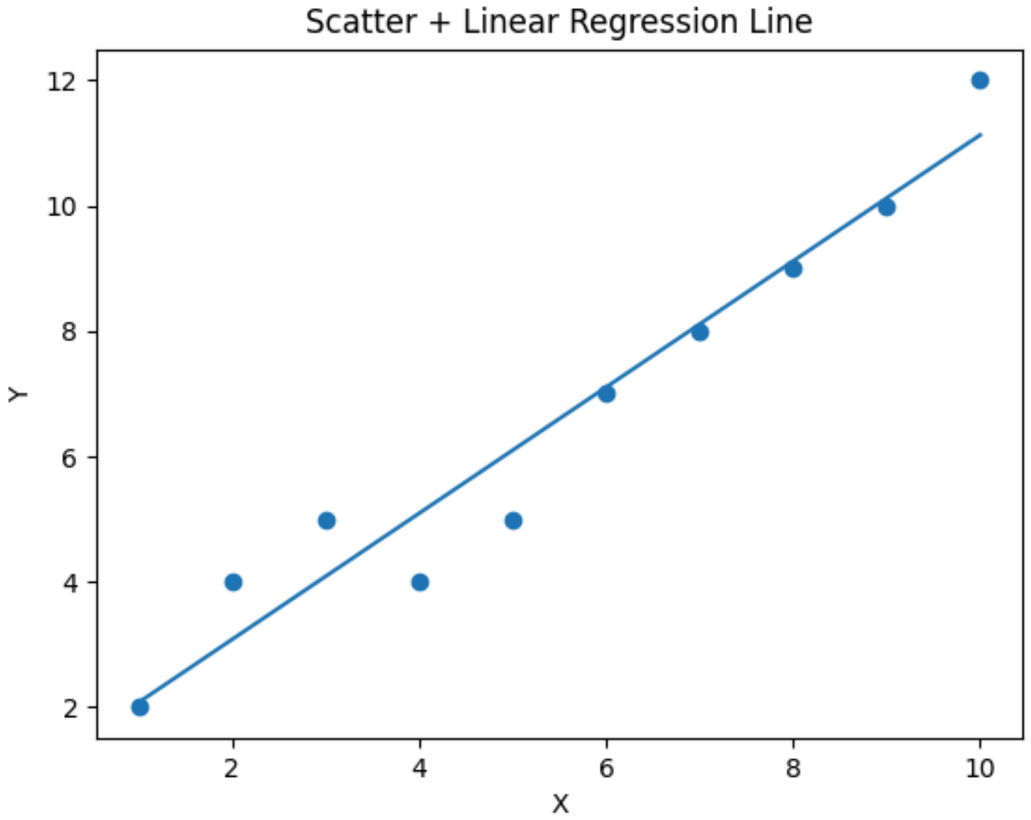

## Notebook 2 10 Minutos

**Dudas, Preguntas, Reflexiones, Opiniones, ETC.**