Analítica de Datos

Clase 4 - Regre Logística y KNN

Antes de preguntarles qué vieron con Pablo...

Congratulaciones a Nachito (Y nico) que ganaron el Hackaton de Anthropic

Ahora si, ¿qué tal con Pablo el martes?

Agenda

- Regre Logística
- KNN
- Notebooks
- Caso de aplicación
- Kahoot

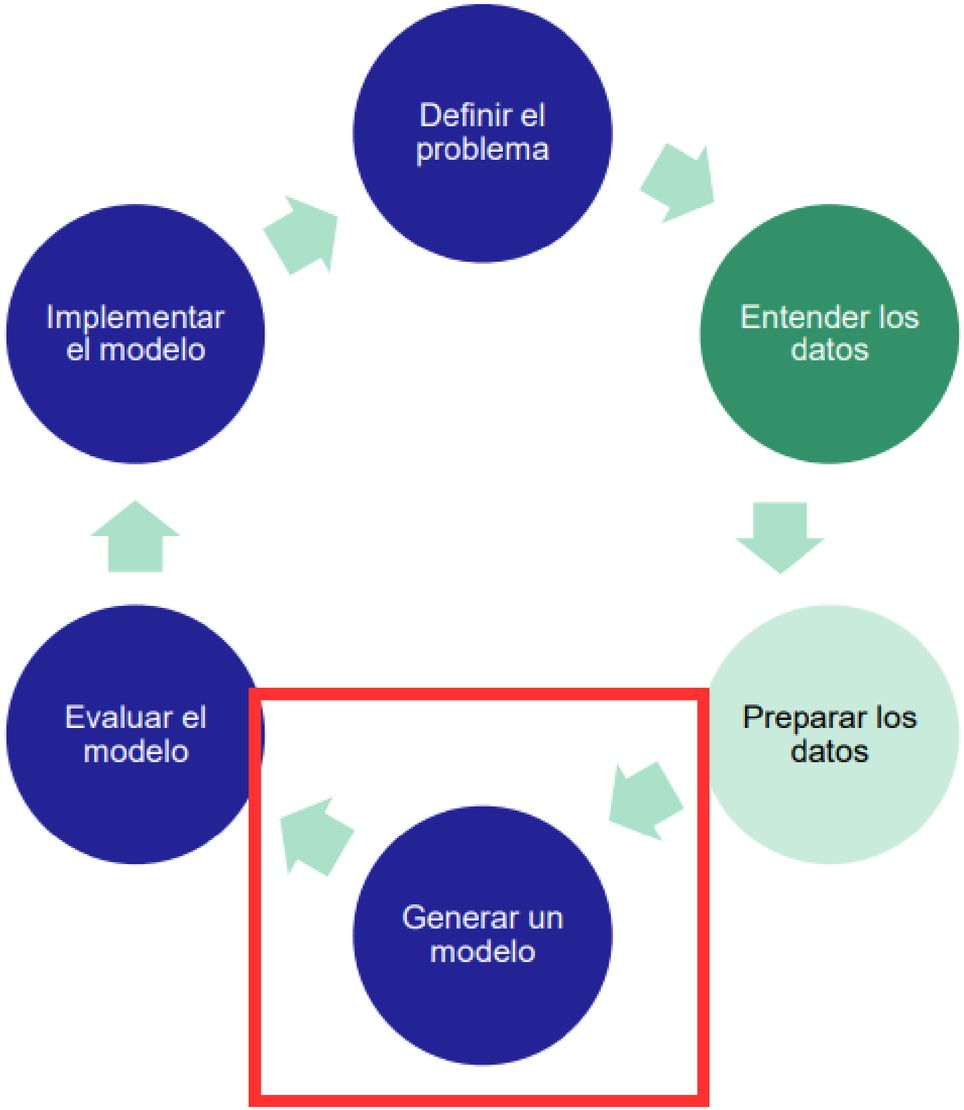
Definir el problema
Entender los datos
Preparar los datos
Generar un modelo
Evaluar el modelo
Implementar el modelo

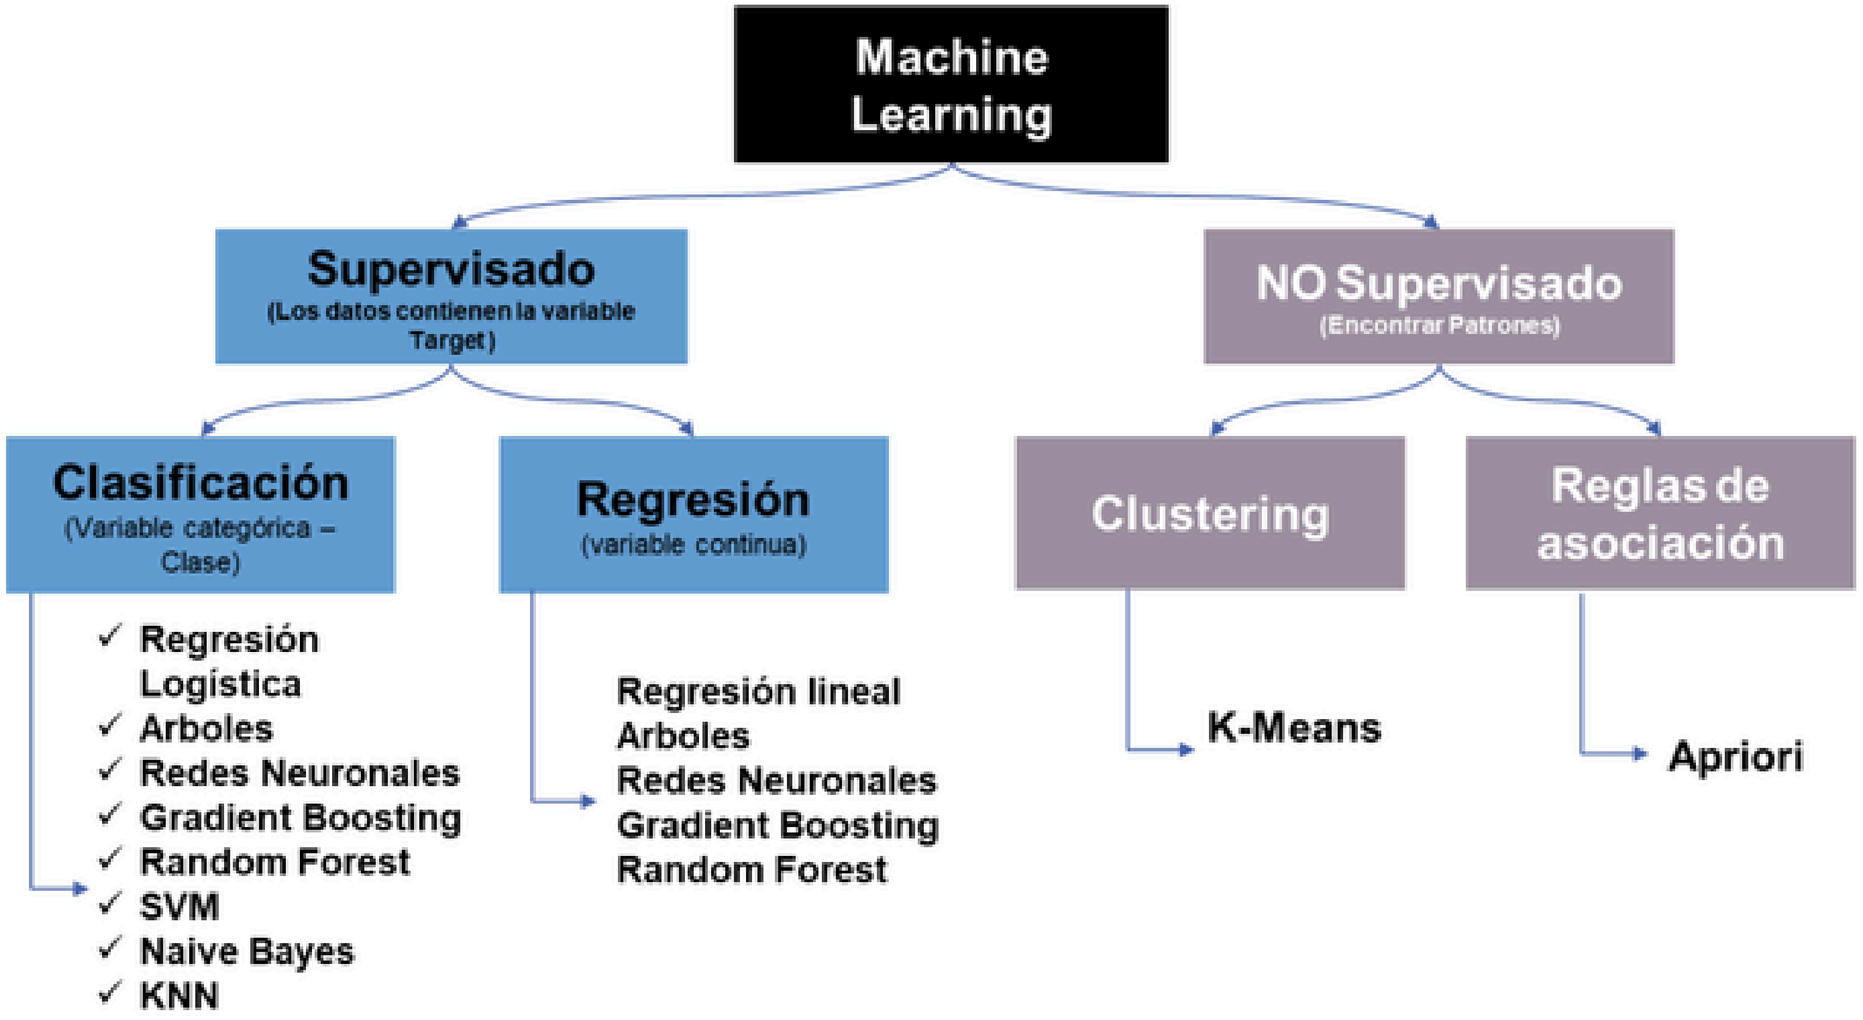
Machine Learning
Supervisado
(Los datos contienen la variable Target)
NO Supervisado
(Encontrar Patrones)
Clasificación
(Variable categórica – Clase)
Regresión
(variable continua)
Clustering
Reglas de asociación
✓ Regresión Logística
✓ Arboles
✓ Redes Neuronales
✓ Gradient Boosting
✓ Random Forest
✓ SVM
✓ Naive Bayes
✓ KNN
Regresión lineal
Arboles
Redes Neuronales
Gradient Boosting
Random Forest
K-Means
Apriori

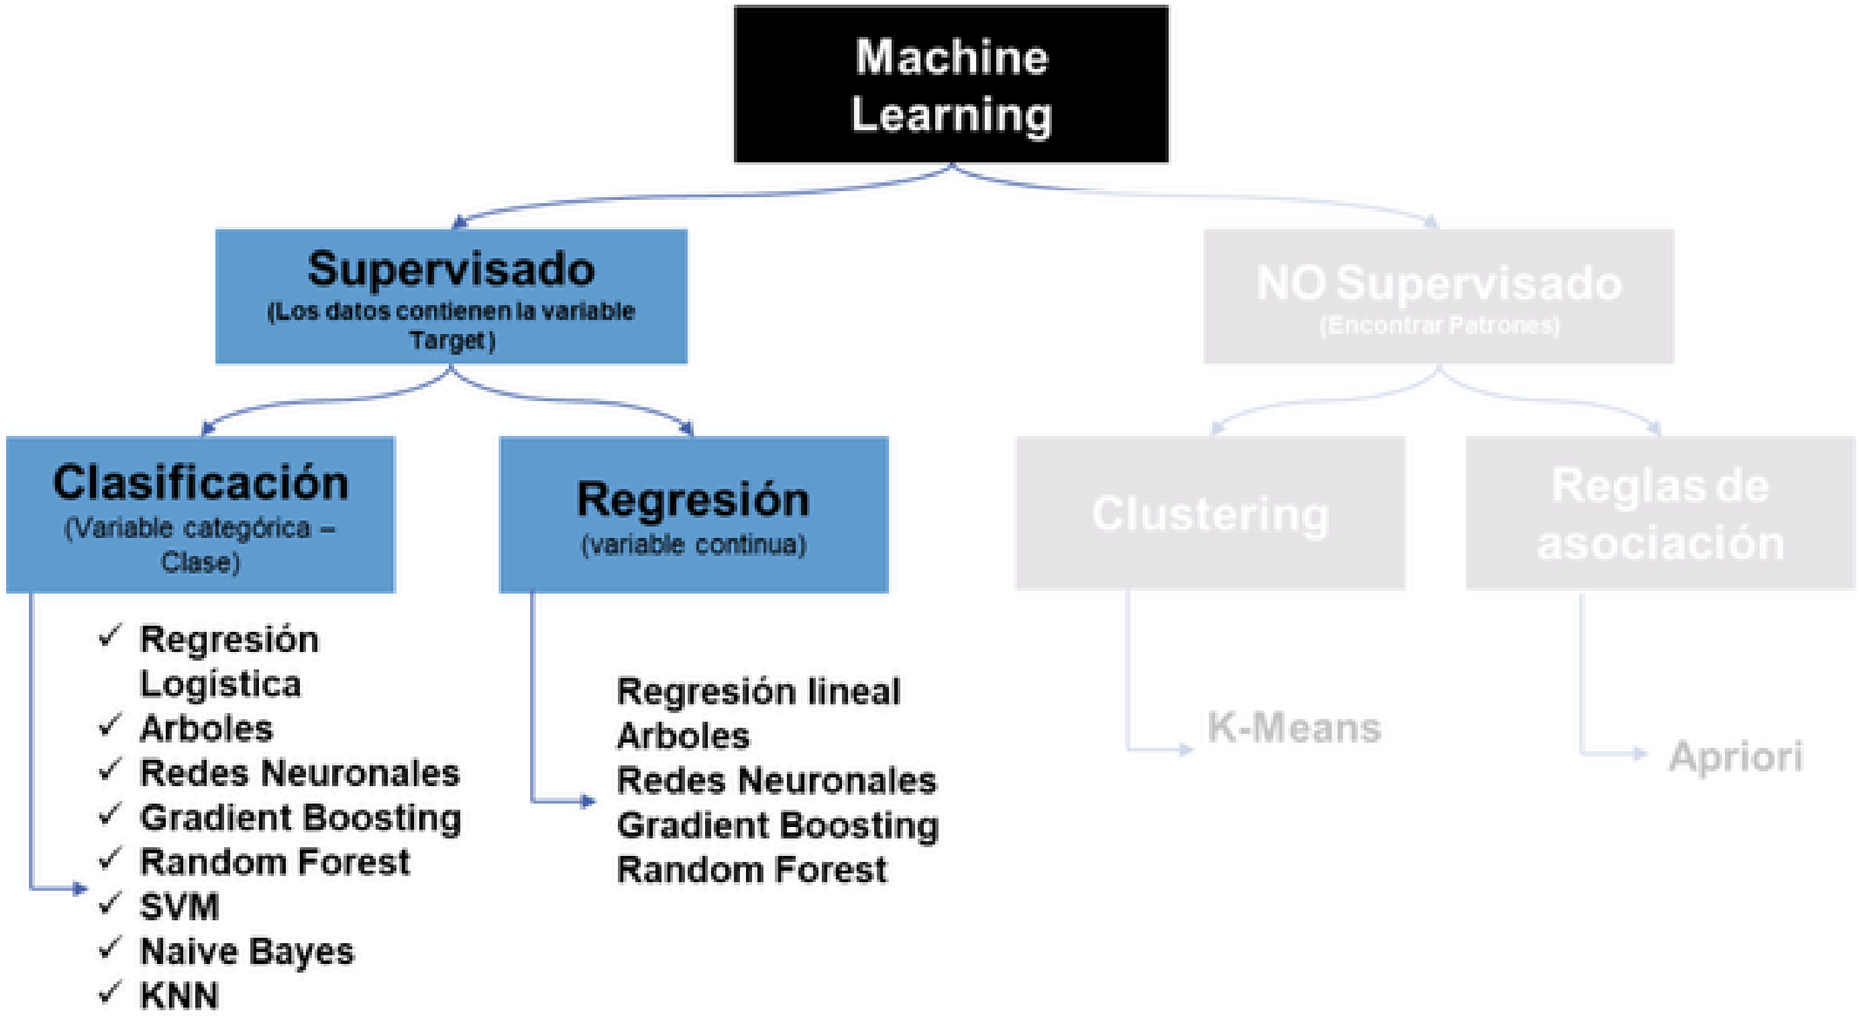
Machine Learning
Supervisado
(Los datos contienen la variable Target)
NO Supervisado
(Encontrar Patrones)
Clasificación
(Variable categórica – Clase)
Regresión
(variable continua)
Clustering
Reglas de asociación
✓ Regresión Logística
✓ Arboles
✓ Redes Neuronales
✓ Gradient Boosting
✓ Random Forest
✓ SVM
✓ Naive Bayes
✓ KNN
Regresión lineal
Arboles
Redes Neuronales
Gradient Boosting
Random Forest
K-Means
Apriori

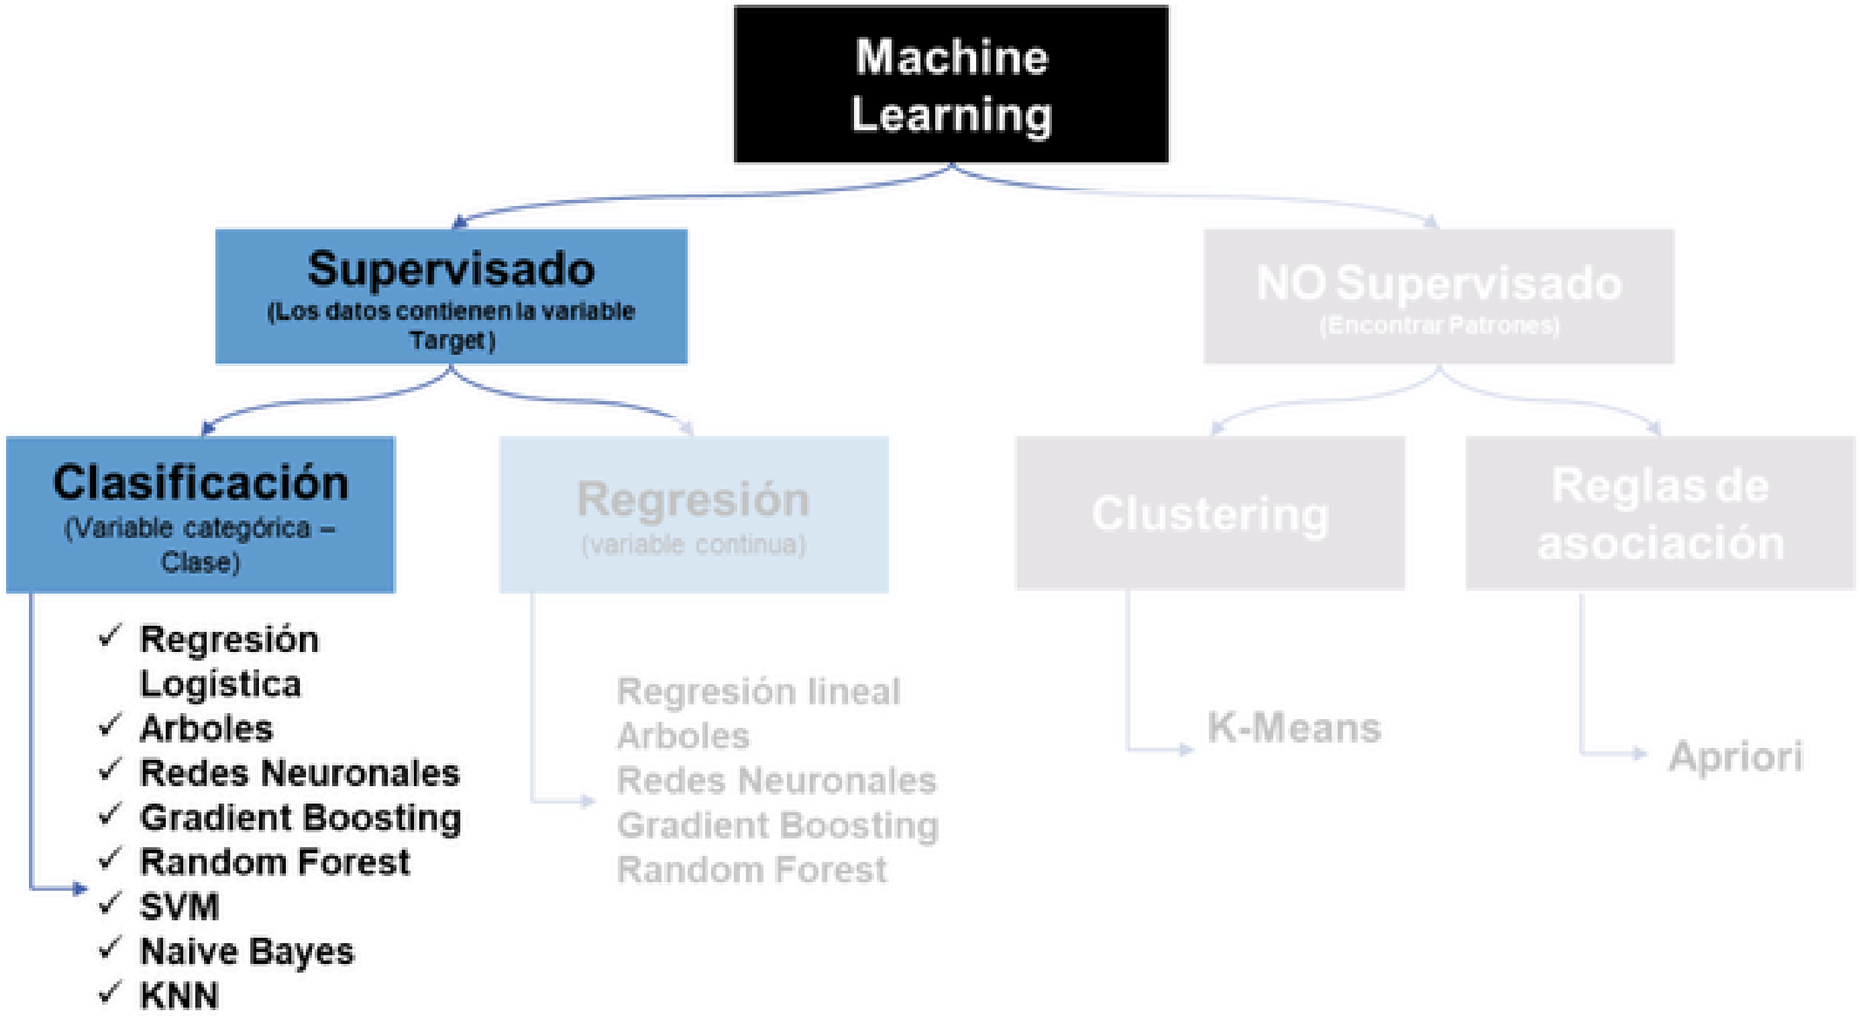
Machine Learning
Supervisado
(Los datos contienen la variable Target)
NO Supervisado
(Encontrar Patrones)
Clasificación
(Variable categórica – Clase)
Regresión
(variable continua)
Clustering
Reglas de asociación
✓ Regresión Logística
✓ Arboles
✓ Redes Neuronales
✓ Gradient Boosting
✓ Random Forest
✓ SVM
✓ Naive Bayes
✓ KNN
Regresión lineal
Arboles
Redes Neuronales
Gradient Boosting
Random Forest
K-Means
Apriori

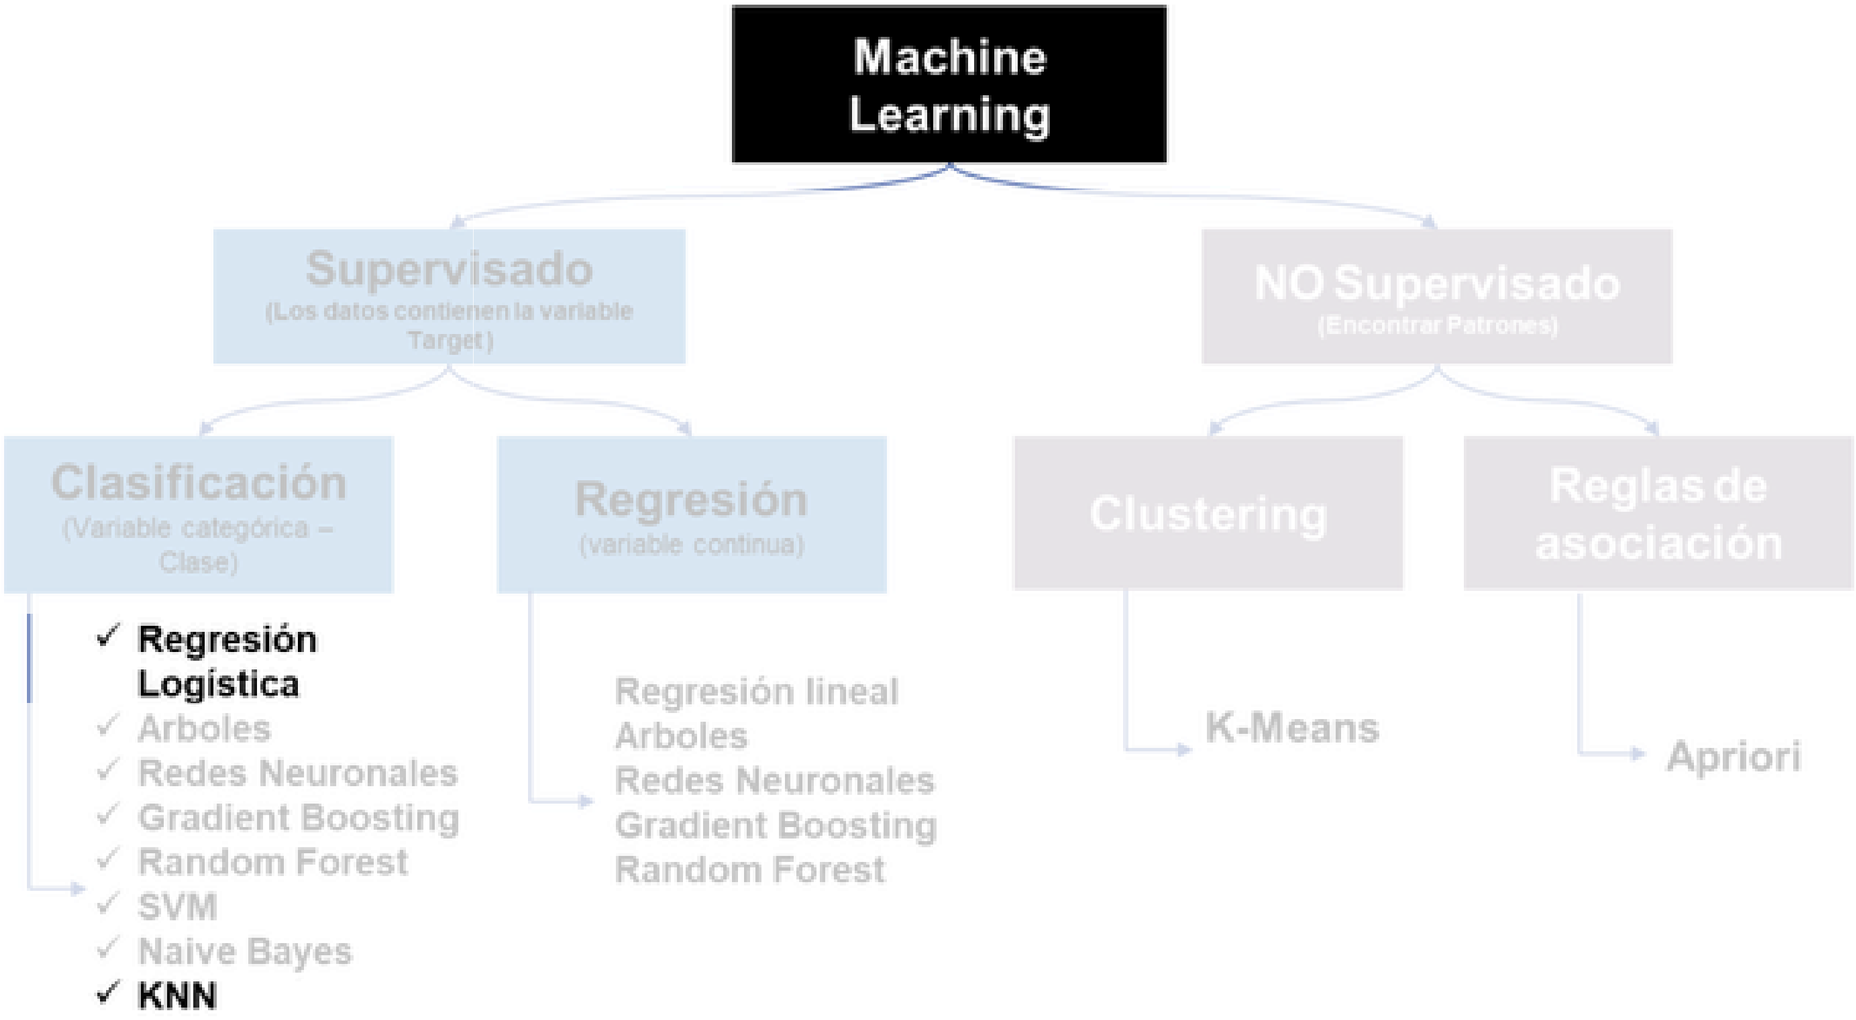
Machine Learning
Supervisado
(Los datos contienen la variable Target)
NO Supervisado
(Encontrar Patrones)
Clasificación
(Variable categórica – Clase)
Regresión
(variable continua)
Clustering
Reglas de asociación
✓ Regresión Logística
✓ Arboles
✓ Redes Neuronales
✓ Gradient Boosting
✓ Random Forest
✓ SVM
✓ Naive Bayes
✓ KNN
Regresión lineal
Arboles
Redes Neuronales
Gradient Boosting
Random Forest
K-Means
Apriori

Regresión Logística

La diferencia con la regresión lineal es...

Regresión Logística

La diferencia con la regresión lineal es qué la regresión lineal predice un número y la regresión logística predice una ***categoría***

Regresión Logística

La diferencia con la regresión lineal es qué la regresión lineal predice un número y la regresión logística predice una ***categoría***

binaria

Regresión Logística

La regresión logística utiliza una fórmula para predecir la probabilidad de que un dato pertenezca a una clase

Regresión Logística

La regresión logística utiliza una fórmula para predecir la probabilidad de que un dato pertenezca a una clase

Cómo predigo probabilidades, la regresión logística va a dar un número entre 0 y 1

Regresión Logística

La regresión logística utiliza una fórmula para predecir la probabilidad de que un dato pertenezca a una clase

Cómo predigo probabilidades, la regresión logística va a dar un número entre 0 y 1

Despues, va a asignar un umbral para decidir si el dato pertenece a la clase A o a la clase B, en función de sus probabilidades

Regresión Logística

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

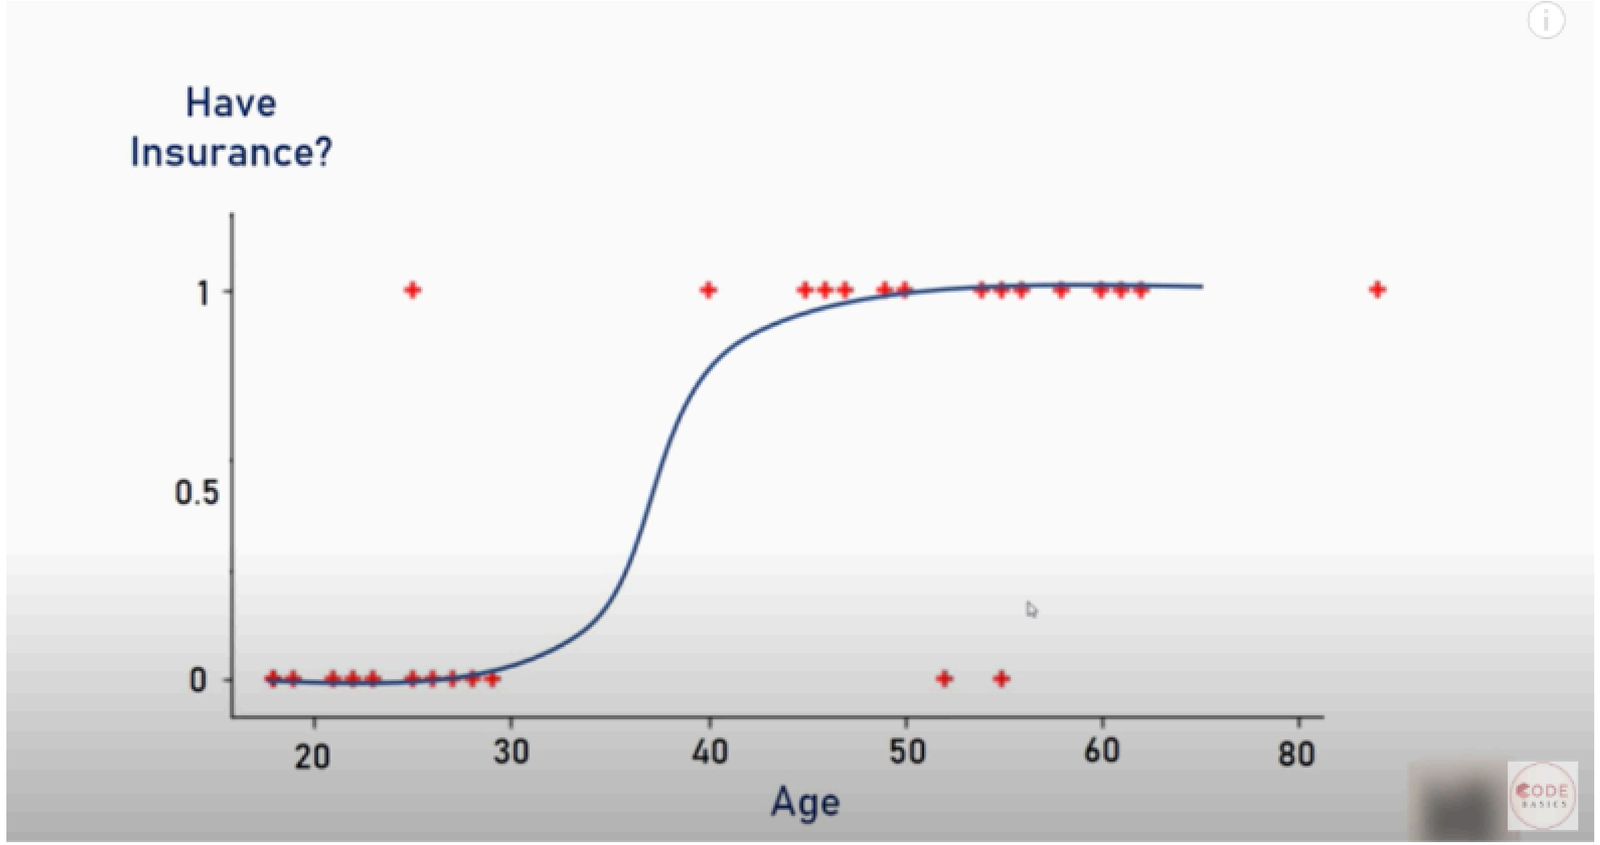

Regresión Logística

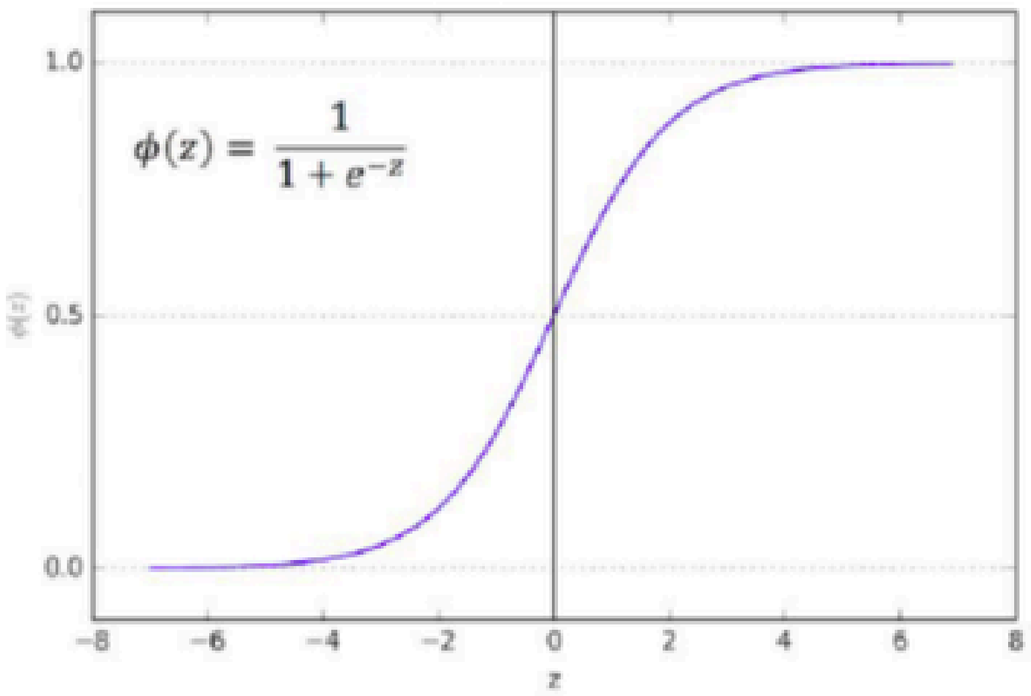

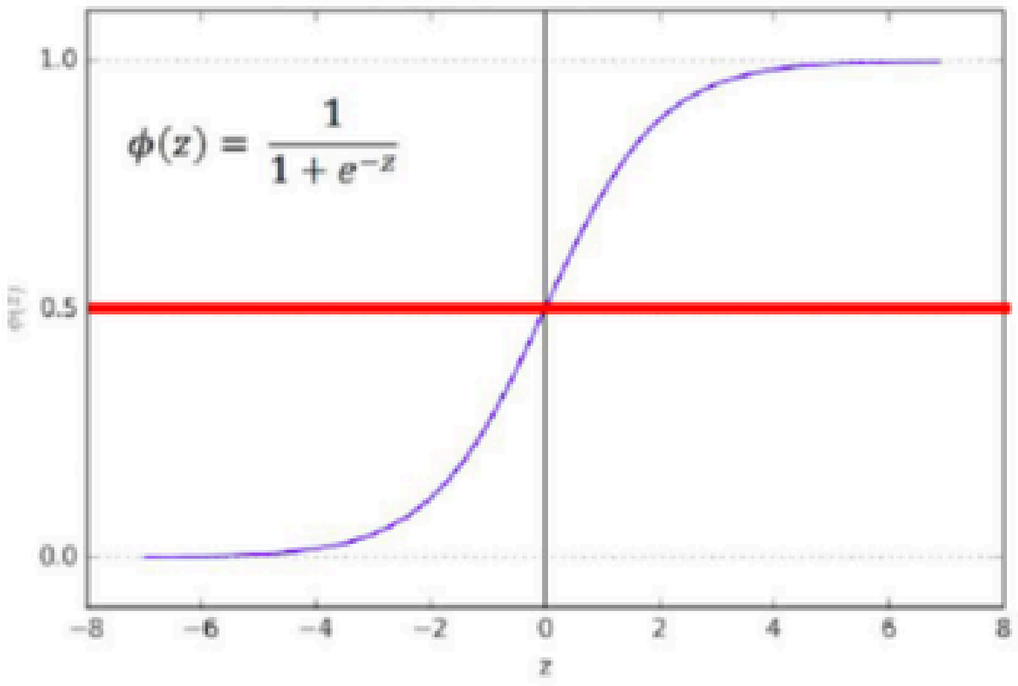

¿Cómo funciona el modelo?

1. Tengo un nuevo punto
2. El modelo calcula la probabilidad de qué ese punto sea de alguna clase
3. Establece un umbral de decisión
4. Predice la categoría

¿Cómo funciona el modelo?

1. Tengo un nuevo punto
2. El modelo calcula la probabilidad de qué ese punto sea de alguna clase
3. Establece un umbral de decisión
4. Predice la categoría

Pregunta medio tramposa...

¿Cómo funciona el modelo?

Si el output de la regresión logística es un número (De 0 a 1), ¿por qué es un modelo de clasificación?

¿Cómo funciona el modelo?

Si el output de la regresión logística es un número (De 0 a 1), ¿por qué es un modelo de clasificación?

Porque la clasificación no depende de la probabilidad, sino del umbral de decisión que le pongamos

¿Cómo funciona el modelo?

¿Cómo elijo mi umbral de decisión?

Regresión Logística

Regresión Logística

Estoy prediciendo si una persona va a cometer un delito
1 = Comete el delito
0 = No comete el delito

Regresión Logística

Estoy prediciendo si una persona va a cometer un delito
1 = Comete el delito
0 = No comete el delito

¿Qué pasa si tengo un umbral de decisión alto? (Cercano a 1)

Regresión Logística

Estoy prediciendo si una persona va a cometer un delito
1 = Comete el delito
0 = No comete el delito

¿Qué pasa si tengo un umbral de decisión alto? (Cercano a 1)

¿Qué pasa si tengo un umbral de decisión bajo? (Cercano a 0)

Regresión Logística

Estoy prediciendo si una persona va a cometer un delito
1 = Comete el delito
0 = No comete el delito

¿Qué pasa si tengo un umbral de decisión alto? (Cercano a 1)

¿Qué pasa si tengo un umbral de decisión bajo? (Cercano a 0)

¿es peor señalar como delincuentes a personas que en realidad no van a cometer ningún delito, o no identificar a quienes sí lo van a cometer?

Regresión Logística

Regresión Logística

Estoy prediciendo si una persona va a faltar a su turno médico
1 = Falta
0 = No falta

Regresión Logística

Estoy prediciendo si una persona va a faltar a su turno médico
1 = Falta
0 = No falta

¿Qué pasa si tengo un umbral de decisión alto? (Cercano a 1)

¿Qué pasa si tengo un umbral de decisión bajo? (Cercano a 0)

Regresión Logística

Estoy prediciendo si una persona va a faltar a su turno médico
1 = Falta
0 = No falta

¿Qué pasa si tengo un umbral de decisión alto? (Cercano a 1)

¿Qué pasa si tengo un umbral de decisión bajo? (Cercano a 0)

¿Es preferible marcar como "faltador" a un paciente que en realidad asistirá a su turno, o asumir que un paciente asistirá cuando en realidad no lo hará?

Regresión Logística

En síntesis, **no hay respuesta correcta** - Uno tiene que ajustar de acuerdo al problema que esté prediciendo

Regresión Logística

Ventajas
Fácil de interpretar
Rápido
Probabilidades claras
Funciona bien con pocos datos

Desventajas
Solo separa de forma lineal
No capta relaciones complejas
Sensible a outliers
Requiere buen feature engineering

KNN

Necesito UN voluntario

KNN

KNN (K-Nearest Neighbors) es un algoritmo de machine learning **supervisado** que:

- Sirve para clasificación y *regresión*
- Se basa en una idea simple
    - Cuanto más cerca estás de algo, más te pareces

Modelos paramétricos y no paramétricos

Algo a tener en cuenta...

Modelos paramétricos y no paramétricos

¿Qué significa que un modelo sea **paramétrico**?

Modelos paramétricos y no paramétricos

¿Qué significa que un modelo sea **paramétrico**?

$$Y = \beta_0 + \beta_1 X_1$$

shutterstock.com · 2110830398

Modelos paramétricos y no paramétricos

¿Qué significa que un modelo sea **paramétrico**?

Que tiene...

$$Y = \beta_0 + \beta_1 X_1$$

shutterstock.com · 2110830398

Modelos paramétricos y no paramétricos

¿Qué significa que un modelo sea **paramétrico**?

Que tiene ¡parámetros!

$$Y = \beta_0 + \beta_1 X_1$$

shutterstock.com · 2110830398

Modelos paramétricos y no paramétricos

¿Qué significa que un modelo sea **no paramétrico**?

Modelos paramétricos y no paramétricos

¿Qué significa que un modelo sea **no paramétrico**?

NO asume una forma fija para la relación entre variables
y
NO tiene un número fijo de parámetros que aprender

“No voy a imponer una fórmula. Voy a dejar que los datos definan la forma.”

Modelos paramétricos y no paramétricos

Regresión: Paramétrico

KNN: No Paramétrico

KNN

KNN es un algoritmo supervisado, de clasificación, no paramétrico

KNN

KNN es un algoritmo supervisado, de clasificación, no paramétrico

¿Cómo funciona KNN?

KNN

1. Aparece un nuevo punto qué quiero predecir
2. Calculo la ***DISTANCIA*** a los otros puntos de mi dataset
3. Elijo cuantos **K** vecinos más cercano quiero considerar
4. Clasifica (Con clase mayoritaria) **o Regresiona** (Con el valor promedio)

KNN

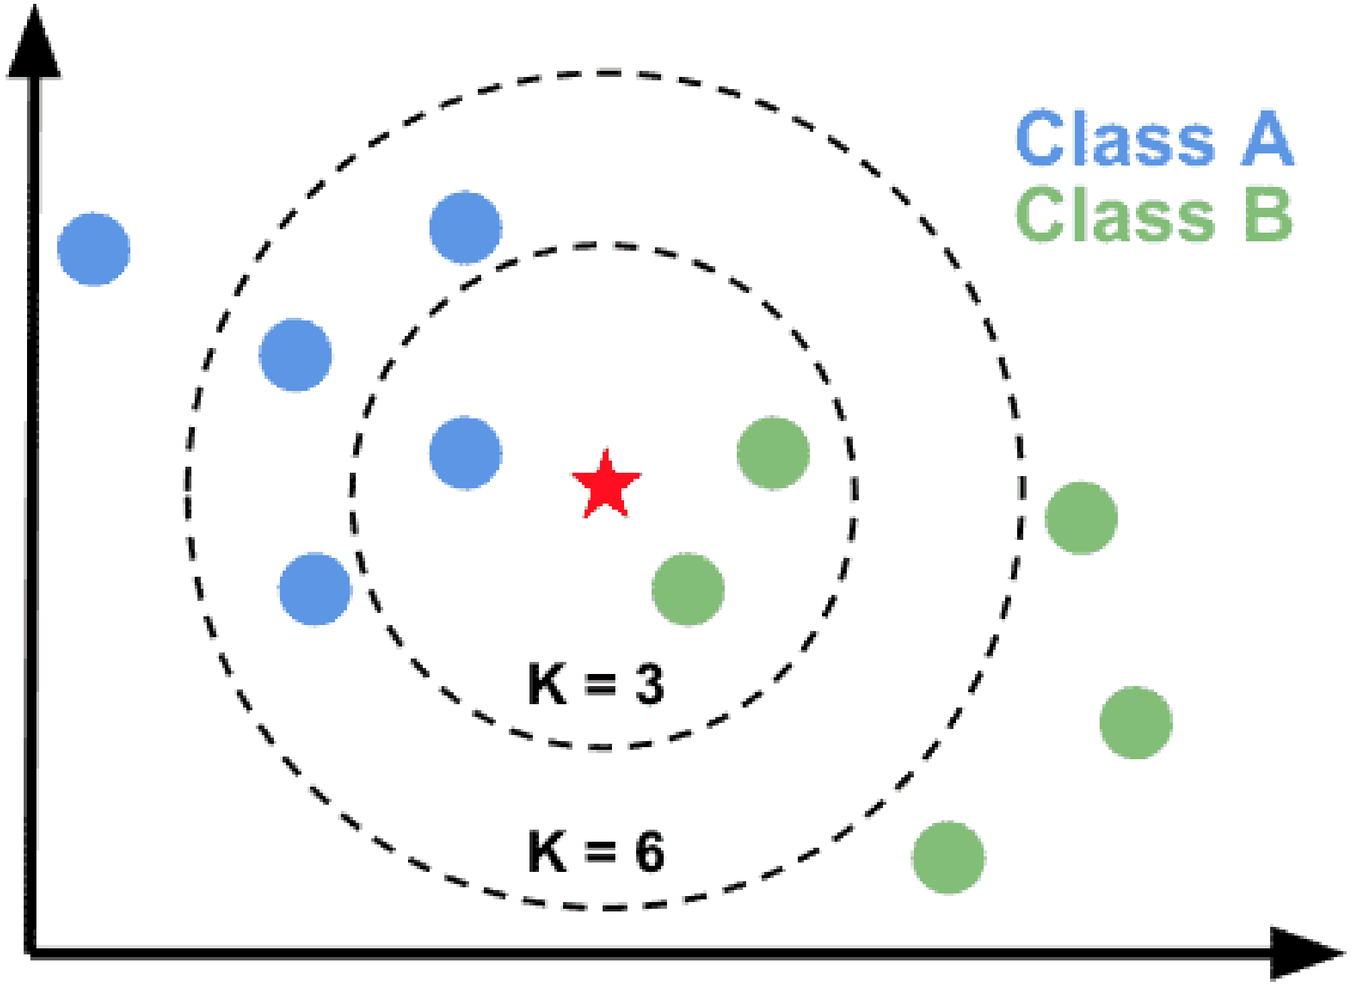

KNN

¿Cual es el K ideal?

KNN

¿Cual es el K ideal? Depende de tu problema

KNN

¿Cual es el K ideal? Depende de tu problema

¿Si tengo un K muy chico?

KNN

¿Cual es el K ideal? Depende de tu problema

¿Si tengo un **K muy chico**? Tengo un modelo muy sensible

KNN

¿Cual es el K ideal? Depende de tu problema

¿Si tengo un **K muy chico**? Tengo un modelo muy sensible

¿Si tengo un **K muy grande**?

KNN

¿Cual es el K ideal? Depende de tu problema

¿Si tengo un **K muy chico**? Tengo un modelo muy sensible

¿Si tengo un **K muy grande**? Tengo un modelo muy general

KNN

¿Cual es el K ideal? Depende de tu problema

¿Si tengo un **K muy chico**? Tengo un modelo muy sensible

¿Si tengo un **K muy grande**? Tengo un modelo muy general

¿Si tengo un **K medio**?

KNN

¿Cual es el K ideal? Depende de tu problema

¿Si tengo un **K muy chico**? Tengo un modelo muy sensible

¿Si tengo un **K muy grande**? Tengo un modelo muy general

¿Si tengo un **K medio**? Hay que encontrar el equilibrio

KNN

¿Cual es el K ideal? Depende de tu problema

¿Si tengo un **K muy chico**? Tengo un modelo muy sensible

¿Si tengo un **K muy grande**? Tengo un modelo muy general

¿Si tengo un **K medio**? Hay que encontrar el equilibrio

K tiene que tener una característica...

KNN

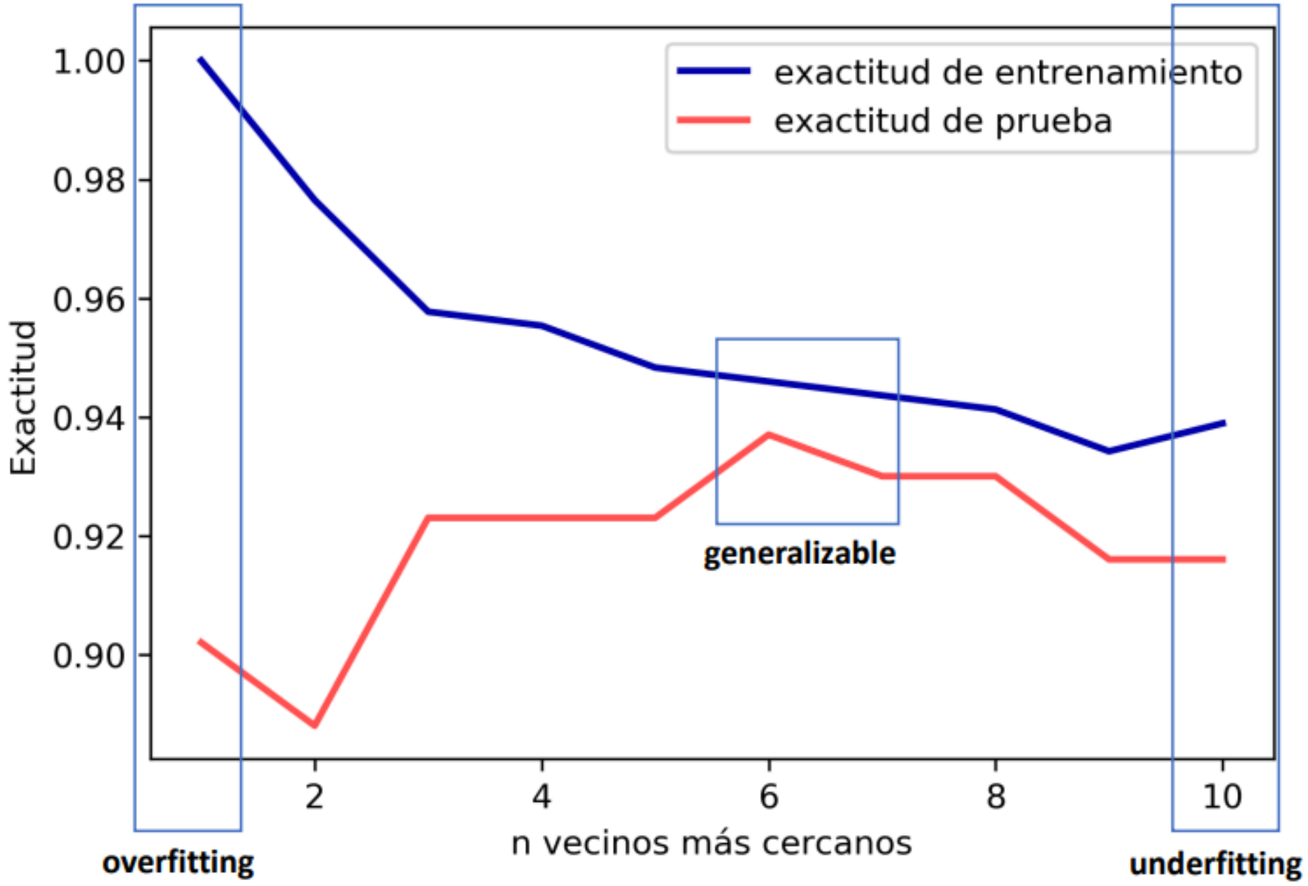
exactitud de entrenamiento
exactitud de prueba
1.00
0.98
0.96
0.94
0.92
0.90
Exactitud
2
4
6
8
10
n vecinos más cercanos
generalizable
overfitting
underfitting

KNN

Tipos de distancia

KNN

Tipos de distancia

Euclidiana
Manhattan
Hamming
Minkowski

KNN

Distancia Euclidiana

La distancia euclidiana es la distancia “normal” en línea recta entre dos puntos en un espacio.

KNN

Distancia Euclidiana

La distancia euclidiana es la distancia “normal” en línea recta entre dos puntos en un espacio.

KNN

Distancia Euclidiana

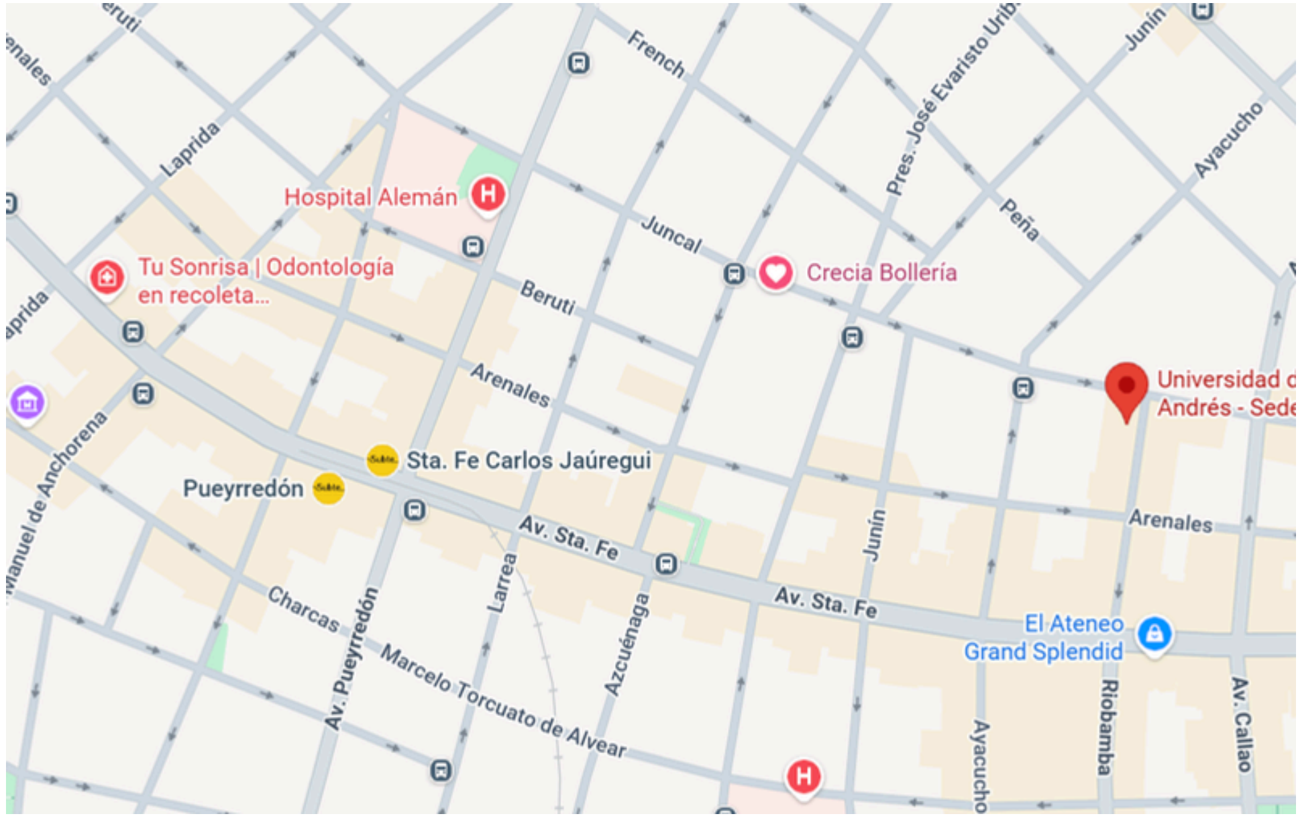

KNN

Distancia Euclidiana

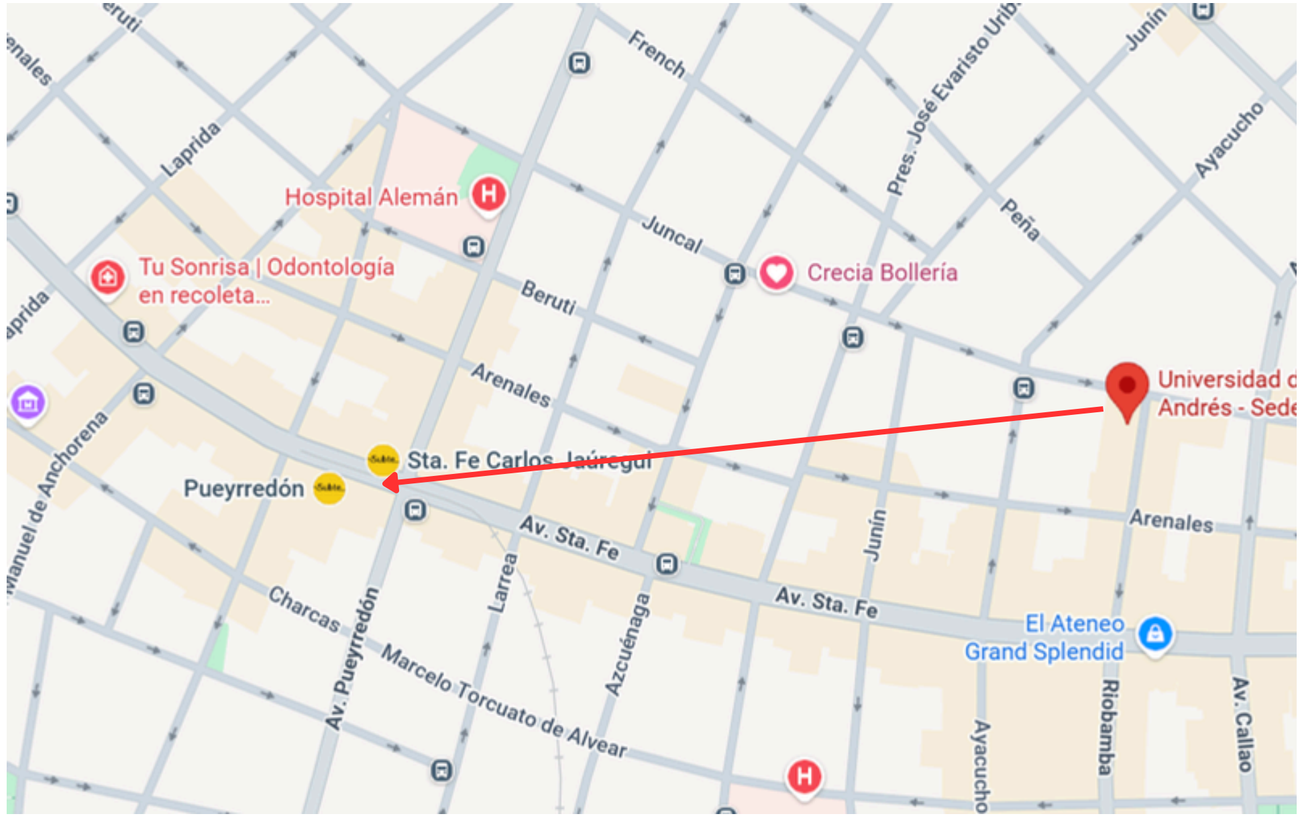

KNN

Distancia de Manhattan

La distancia Manhattan mide la distancia entre dos puntos sumando las diferencias absolutas en cada dimensión

No vas en línea recta, sino “en L” (horizontal + vertical), como si no pudieras cortar en diagonal.

KNN

Distancia Manhattan

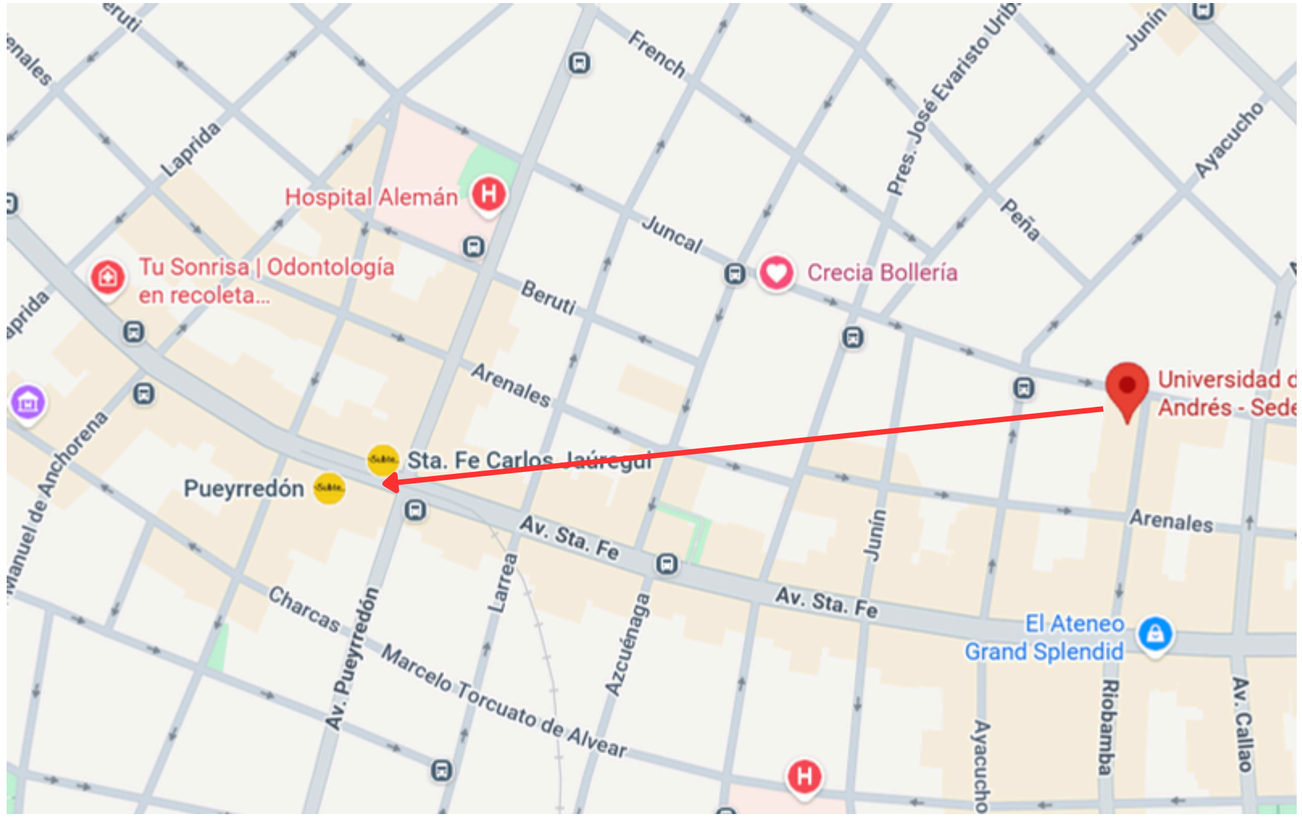

KNN

Distancia Manhattan

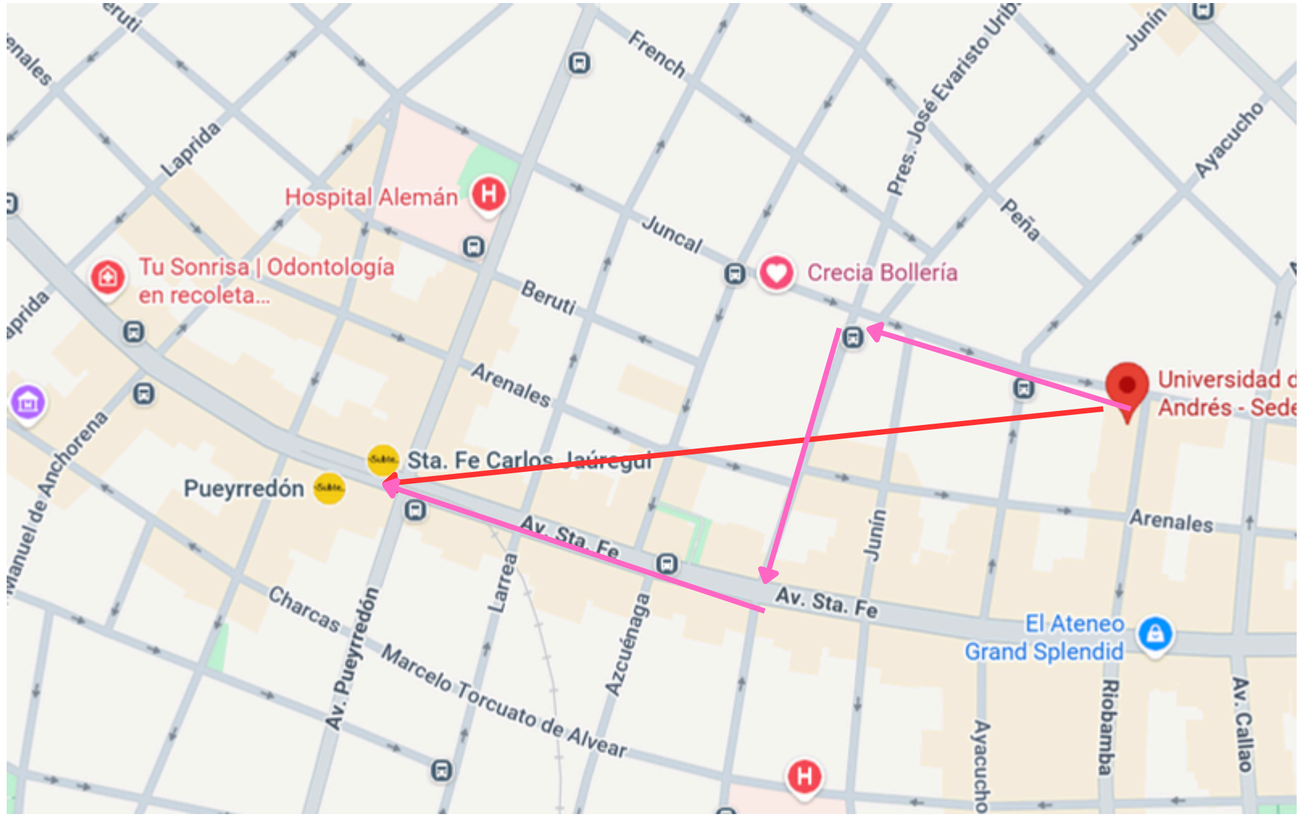

KNN

¿Qué distancia uso?

KNN

¿Qué distancia uso? DEPENDE

KNN

El problema de la distancia

KNN es muy sensible a la escala

KNN

El problema de la distancia

KNN es muy sensible a la escala

Edad 0-100
Ingreso 0-1.000.000

Toda mi distancia va a estar **dominada** por la variable ingreso, y los cambios en la edad no van a ser muy determinantes.

KNN

El problema de la distancia

¿Cómo lo soluciono?

KNN

El problema de la distancia

¿Cómo lo soluciono?

Estandarizando / Normalizando

KNN

Persona	Edad	Ingresos
A	22	25,000
B	25	30,000
C	28	45,000
D	30	50,000
E	35	60,000
F	40	200,000
G	45	300,000
H	50	500,000
I	55	700,000
J	60	900,000

KNN

StandardScaler

$$z = \frac{x - \mu}{\sigma}$$

Calculo la media y la desviación standard

KNN

Persona	Edad (z)	Ingresos (z)
A	-1.36	-0.88
B	-1.12	-0.86
C	-0.88	-0.81
D	-0.72	-0.79
E	-0.32	-0.76
F	0.08	-0.28
G	0.48	0.07
H	0.88	0.75
I	1.28	1.45
J	1.68	2.14

KNN

El problema de la distancia

¿Cómo lo soluciono?

Estandarizando / Normalizando

StandardScaler → datos normales, uso general
MinMaxScaler → cuando necesitás valores entre 0 y 1
RobustScaler → cuando hay outliers
MaxAbsScaler → datos sparse (muchos ceros)

KNN

Ejemplos...

KNN

Ejemplos...

Diagnóstico médico
Algoritmo de recomendaciones
Precio de propiedades
Desempeño de estudiantes

KNN

Ventajas de KNN
Fácil de entender e implementar
Sirve para clasificación y regresión
Puede capturar relaciones complejas

Desventajas de KNN
Lento en predicción (compara con todos los datos)
Sensible a la escala de variables
Depende de la métrica de distancia
Sensible al ruido y outliers
Problemas en alta dimensión (curse of dimensionality)

Regre Logística + KNN

Notebook

Repaso

Machine Learning
Aprende patrones de datos para predecir o tomar decisiones.

Modelo
Función que aprende de los datos y genera predicciones.

Supervisado
Aprende usando datos con variable objetivo (target).

No Supervisado
Encuentra patrones sin variable objetivo.

Clasificación
Predice categorías (ej: sí/no, spam/no spam).

Regresión
Predice valores numéricos continuos.

Repaso

Regresión Lineal
Modelo que predice valores usando una relación lineal.

Regresión Logística
Modelo que predice probabilidades para clasificar.

KNN
Predice según los vecinos más cercanos.

Distancia
Mide qué tan similares son los datos (ej: euclidiana).

Paramétrico
Modelo con forma fija y parámetros definidos.

No Paramétrico
Modelo flexible que se adapta a los datos.

Repaso

Overfitting
Aprende demasiado → no generaliza.

Underfitting
Aprende poco → mal desempeño.

Umbral de decisión
Define cómo se asigna una clase.

Escalado de datos
Ajusta variables para que sean comparables.

Repaso

Data Cleaning
Proceso de limpiar y preparar los datos.

Datos nulos
Valores faltantes que deben tratarse.

Outliers
Valores extremos que pueden afectar el modelo

Inconsistencias
Datos mal cargados o con formatos distintos.